



МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(национальный исследовательский университет)»

Институт (Филиал) № 8 «Компьютерные науки и прикладная математика» Кафедра 806
Группа М8О-209СВ-24 Направление подготовки 02.04.02 «Фундаментальная
информатика и информационные технологии»

Программа Информатика

Квалификация: инженер-исследователь

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

На тему: Оптимизация холодного старта и масштабирования моделей машинного обучения
в бессерверном инференсе для обеспечения высокой доступности

Автор ВКР: _____ Блинов Максим Алексеевич (_____)

Научный руководитель: _____ Булакина Мария Борисовна (_____)

Консультант: _____ — (_____)

Консультант: _____ — (_____)

Рецензент: _____ — (_____)

К защите допустить

Заведующий кафедрой 806 _____ Крылов Сергей Сергеевич (_____)

____ июня 2026 года

РЕФЕРАТ

Выпускная квалификационная работа состоит из 106 страниц, 6 рисунков, 7 таблиц, 44 использованных источников.

ИИ, ОБЛАЧНАЯ ПЛАТФОРМА, БОЛЬШАЯ ЯЗЫКОВАЯ МОДЕЛЬ, МАШИННОЕ ОБУЧЕНИЕ, БЕССЕРВЕРНЫЕ ВЫЧИСЛЕНИЯ, ХОЛОДНЫЙ СТАРТ, ИНФЕРЕНС, КЭШИРОВАНИЕ, KUBERNETES, KUBEBUILDER, CONTAINER STORAGE INTERFACE, P2P, FUSE, МИКРОСЕРВИСЫ, GOLANG, HIGHLOAD

Объектом разработки в данной работе является инфраструктура бессерверного инференса моделей машинного обучения, развернутая в среде Kubernetes с применением механизма масштабирования до нуля.

Предмет исследования — методы кэширования, доставки и виртуализации доступа к файлам весов ML-моделей при холодном старте инференс-подов в Kubernetes-кластере.

Цель работы — Сокращение задержки холодного старта, уменьшение нагрузки на внешние реестры моделей и повышение доступности системы при горизонтальном масштабировании путем разработки архитектуры распределенного кэширования файлов моделей машинного обучения для бессерверного инференса в Kubernetes. Для достижения поставленной цели проведен анализ причин холодного старта и влияния роста размеров ML-моделей на инфраструктуру инференса; исследованы существующие распределенные решения для кэширования моделей — Alluxio, JuiceFS, Dragonfly, CubeFS, Rook/Ceph; реализована специализированная система распределенного chunk-кэша, включающая агент storage-agent, работающий как DaemonSet на каждой worker-ноде, FUSE-клиент storage-mounter, предоставляющий ML-runtime стандартный файловый интерфейс, и Redis-кластер в роли реестра метаданных чанков и активных агентов; сформирована методика оценки эффективности предложенной архитектуры.

Ключевые методы — трехуровневое кэширование по схеме «локальный диск — соседняя нода — внешний репозиторий»; FUSE-монтирование виртуальной файловой системы; P2P-доставка чанков между агентами по TCP; локальная связь через Unix Domain Socket; Redis heartbeat как реестр метаданных; атомарная запись чанков во избежание гонки

и частично загруженных данных.

Ожидаемые результаты — снижение количества повторных загрузок весов из внешнего репозитория, уменьшение нагрузки на HuggingFace Hub, ускорение холодного старта при наличии локального или соседнего кэша, устранение NFS как единственной точки отказа.

СОДЕРЖАНИЕ

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ	7
ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ	9
ВВЕДЕНИЕ	11
1 ПРОБЛЕМА ХОЛОДНОГО СТАРТА ML-МОДЕЛЕЙ В БЕССЕРВЕРНОМ ИНФЕРЕНСЕ	17
1.1 Эволюция размеров моделей машинного обучения	17
1.1.1 От компактных сетей к масштабным языковым моделям .	17
1.1.2 Экспоненциальный рост весов языковых моделей	18
1.1.3 Законы масштабирования как движущая сила роста	19
1.2 Механизм холодного старта в Kubernetes	20
1.2.1 Декомпозиция задержки холодного старта	20
1.2.2 Фаза планирования: T_{schedule}	21
1.2.3 Фазы загрузки и распаковки образа: $T_{\text{pull}} + T_{\text{unpack}}$	21
1.2.4 Фаза init-контейнера: T_{init}	21
1.2.5 Фаза загрузки весов из репозитория: T_{download}	22
1.2.6 Ограничения схемы с <code>emptyDir</code>	22
1.2.7 Фаза загрузки в GPU-память: T_{load}	23
1.2.8 Итоговый характер задержки	23
1.3 Влияние холодного старта на SLA, пользовательский опыт и стоимость	23
1.3.1 SLA и метрики задержки	23
1.3.2 Закон Литтла: накопление ожидающих запросов	24
1.3.3 Вероятность холодного старта при стратегии scale-to-zero .	25
1.3.4 Дилемма scale-to-zero и over-provisioning	26
1.3.5 Влияние на пользовательский опыт	27
1.4 Требования к системе оптимизации холодного старта	27
1.4.1 Функциональные требования	27
1.4.2 Нефункциональные требования	28
1.5 Выводы по разделу	29
2 АНАЛИЗ СУЩЕСТВУЮЩИХ РЕШЕНИЙ ДЛЯ ХРАНЕНИЯ И КЭШИРОВАНИЯ МОДЕЛЕЙ	31
2.1 Критерии сравнения решений	31
2.2 Alluxio	32

2.3	JuiceFS	35
2.4	Dragonfly, CubeFS и Rook/Ceph	37
2.5	Сравнительная таблица	40
2.6	Обоснование разработки специализированного решения	41
2.7	Выводы по разделу	43
3	ПРОМЕЖУТОЧНОЕ РЕШЕНИЕ НА БАЗЕ NFS И КООРДИНАЦИИ ЗАГРУЗОК	44
3.1	Исходная схема: storage-initializer и emptyDir	44
3.2	Переход к NFS как общему хранилищу	45
3.3	Проблема параллельного скачивания и условие гонки	47
3.4	Файловые блокировки flock и их особенности поверх NFS . . .	50
3.5	Kubernetes Lease и Leader Election	52
3.6	Ограничения NFS-этапа	55
3.7	Выводы по разделу	56
4	РАЗРАБОТКА P2P/FUSE-СИСТЕМЫ КЭШИРОВАНИЯ ML-MODEЛЕЙ	58
4.1	Общая идея и требования к архитектуре	58
4.2	Модель данных: репозиторий, модель, ревизия, файл, чанк . . .	60
4.3	Redis как реестр метаданных чанков	62
4.4	Обнаружение узлов: Gossip, mDNS и Redis heartbeat	64
4.5	Компонент storage-agent: DaemonSet-агент на каждой ноде . . .	67
4.6	Компонент storage-mounter: FUSE-клиент	71
4.7	UDS и TCP: разделение локальной и междоузовой коммуникации	76
4.8	Алгоритм чтения чанка	78
4.9	Политика кэширования и вытеснения	80
4.10	Параллельная загрузка, выбор пира и prefetching	82
4.11	Надёжность и высокая доступность	84
4.12	Выводы по разделу	86
5	ОЦЕНКА ЭФФЕКТИВНОСТИ И НАДЁЖНОСТИ ПРЕДЛОЖЕННОГО ПОДХОДА	88
5.1	Методика экспериментов	88
5.2	Метрики оценки	89
5.3	Расчётная модель задержки	90
5.4	Ожидаемые результаты сравнения	93
5.5	Анализ сценариев отказов	94

5.6	Ограничения предложенного подхода	96
5.7	Выводы по разделу	97
ЗАКЛЮЧЕНИЕ		99
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ		103

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

В настоящей выпускной квалификационной работе применяют следующие термины с соответствующими определениями:

Инференс — процесс получения предсказаний от обученной модели машинного обучения по новым входным данным без изменения ее параметров

Холодный старт — состояние, при котором инстанс сервиса инференса создается с нуля и перед обработкой первого запроса должен выполнить полную инициализацию, включая загрузку файлов модели

Весы модели — набор числовых параметров нейросети, определяющих ее поведение и загружаемых в оперативную и видеопамять перед инференсом

Чанк — фрагмент файла весов фиксированного размера, используемый как минимальная единица кэширования, репликации и P2P-передачи

Бессерверные вычисления — модель развертывания, при которой платформа автоматически управляет выделением и освобождением вычислительных ресурсов в зависимости от нагрузки, включая масштабирование до нуля

Pod — минимальная единица развертывания в Kubernetes, объединяющая один или несколько контейнеров с общим сетевым пространством имен и томами хранения

DaemonSet — ресурс Kubernetes, обеспечивающий запуск экземпляра служебного пода на каждой подходящей worker-ноде кластера

Scale-to-zero — способность платформы снижать число активных реплик сервиса до нуля при отсутствии входящих запросов

Control Plane — плоскость управления, в рамках работы представленная Redis-реестром метаданных о чанках и состоянии агентов

Data Plane — плоскость данных, включающая локальные диски worker-нод, каналы доставки чанков и компоненты, непосредственно обслуживающие чтение весов модели

Реестр метаданных — служба, хранящая сведения о расположении чанков, их размере, контрольных суммах и доступных узлах-держателях

Файловая система в пространстве пользователя (FUSE) — механизм Linux, позволяющий реализовать файловую систему как пользовательский процесс с обработкой обращений через VFS

Сокет домена Unix — механизм межпроцессного взаимодействия внутри одного узла, использующий файловую систему вместо IP-стека

Сетевая файловая система — протокол распределенного доступа к удаленным файлам, позволяющий монтировать удаленный каталог как локальный

`flock` — системный вызов для установки рекомендательных файловых блокировок, используемый для координации параллельных загрузок

`Lease` — ресурс Kubernetes Coordination API, представляющий временной токен владения и применяемый для распределенной координации

`Leader Election` — алгоритм выбора единственного активного исполнителя привилегированной операции среди конкурирующих процессов

`Cache hit` — ситуация, при которой запрошенные данные найдены в кэше и возвращаются без обращения к более медленному источнику

`Cache miss` — ситуация, при которой данные отсутствуют в текущем уровне кэша и требуется переход к следующему источнику

`Fallback` — механизм переключения на резервный источник данных при отсутствии или недоступности основного пути чтения

Единственная точка отказа — компонент системы, отказ которого приводит к полной недоступности критически важной функциональности

Обнаружение узлов — процесс получения актуального списка агентов, которые могут обслуживать запросы на чтение конкретных чанков модели

Предзагрузка — заблаговременная загрузка следующих чанков на основе наблюдаемого паттерна чтения для сокращения задержки последующих запросов

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ

В настоящей выпускной квалификационной работе применяют следующие сокращения и обозначения:

ML — Machine Learning — машинное обучение

LLM — Large Language Model — большая языковая модель

SLA — Service Level Agreement — соглашение об уровне обслуживания

SLO — Service Level Objective — целевой показатель уровня обслуживания

K8s — Kubernetes — система оркестрации контейнеров

P2P — Peer-to-Peer — одноранговая сеть

FUSE — Filesystem in Userspace — файловая система в пространстве пользователя

UDS — Unix Domain Socket — сокет домена Unix

TCP — Transmission Control Protocol — протокол управления передачей

NFS — Network File System — сетевая файловая система

PV — PersistentVolume — постоянный том Kubernetes

PVC — PersistentVolumeClaim — заявка на постоянный том Kubernetes

RWX — ReadWriteMany — режим доступа к тому Kubernetes для нескольких нод

API — Application Programming Interface — программный интерфейс приложения

RTT — Round-Trip Time — время двойного прохода сигнала

BDP — Bandwidth-Delay Product — произведение полосы пропускания на задержку

IPC — Inter-Process Communication — межпроцессное взаимодействие

VFS — Virtual File System — виртуальная файловая система

LRU — Least Recently Used — алгоритм вытеснения наименее давно используемых данных

TTL — Time-To-Live — время жизни записи в кэше или реестре

HA — High Availability — высокая доступность

SPOF — Single Point of Failure — единственная точка отказа

CDN — Content Delivery Network — сеть доставки содержимого

CNN — Convolutional Neural Network — сверточная нейронная сеть

RNN — Recurrent Neural Network — рекуррентная нейронная сеть

GPU — Graphics Processing Unit — графический процессор

CPU — Central Processing Unit — центральный процессор

AMAT — Average Memory Access Time — среднее время доступа к данным

mDNS — Multicast DNS — многоадресный DNS

CNI — Container Network Interface — сетевой интерфейс контейнеров

CSI — Container Storage Interface — интерфейс хранилища контейнеров

ВВЕДЕНИЕ

Актуальность темы

Развитие методов машинного обучения привело к смещению отрасли от относительно небольших классических моделей к крупным языковым моделям (LLM, Large Language Model), мультимодальным архитектурам и диффузионным генераторам. Число параметров современных моделей выросло с сотен миллионов (BERT [1], 2018) до сотен миллиардов (Llama 3 70B [2], Falcon 180B [3]), а размер хранимых весов — с сотен мегабайт до сотен гигабайт. Несмотря на тенденцию к повышению плотности возможностей моделей [4], state-of-the-art результаты по-прежнему требуют архитектур колоссального масштаба.

Одновременно индустрия уверенно движется в сторону бессерверного инференса (serverless inference) — модели эксплуатации, при которой облачная платформа автоматически масштабирует сервисы в ответ на изменение нагрузки, включая масштабирование до нуля активных реплик при отсутствии входящих запросов. Данная модель реализована в таких платформах, как Knative [5] — открытый стандарт на базе Kubernetes, поддерживаемый Google, IBM и Red Hat; OpenFaaS — система развёртывания функций в Kubernetes-кластере; Amazon Web Services Lambda — управляемая serverless-платформа публичного облака; а также KServe [6] — стандартизованная платформа для ML-инференса с поддержкой scale-to-zero. Эти платформы позволяют значительно экономить ресурсы кластера: ноды не удерживают вычислительные мощности для простаивающих сервисов, а плата взимается только за фактически обработанные запросы.

Однако serverless-модель вступает в острое противоречие с природой современных ML-моделей. Перед началом обработки запросов контейнер инференса должен загрузить файлы весов из внешнего репозитория или общего хранилища. Для модели весом 15–350 ГБ такая загрузка занимает от нескольких минут до десятков минут даже по высокоскоростному каналу. По оценкам, опубликованным командой BentoML [7], при стандартном подходе загрузка весов LLM-модели размером 15 ГБ может занимать свыше 10 минут, что неприемлемо для большинства реальных сервисов. Таким образом, холодный старт (cold start) — задержка от момента появления запроса до готовности сервиса его обработать — становится не техническим

неудобством, а фактором, определяющим выполнимость SLA (Service Level Agreement, соглашение об уровне обслуживания) в продуктивных системах.

Актуальность задачи оптимизации холодного старта подтверждается и отраслевыми тенденциями: доля ML-нагрузок в публичных облаках стремительно растёт, а требования к задержке инференса ужесточаются. Пользовательские интерфейсы генеративного ИИ — чаты, ассистенты, системы рекомендаций — создают нагрузки с ярко выраженной пиковостью, при которых платформа обязана быстро масштабировать парк реплик. С экономической точки зрения serverless-инференс привлекателен: оператор платит только за реально затраченные вычислительные ресурсы, а не за простаивающие GPU-инстансы. Однако реализация этой экономии требует, чтобы время масштабирования сервиса было значительно меньше времени ожидания пользователя. Для нагрузок реального времени приемлемое время ответа составляет единицы секунд, тогда как задержка холодного старта при загрузке крупных моделей измеряется минутами. Это противоречие делает задачу оптимизации холодного старта одной из центральных в области MLOps и инфраструктуры ML-платформ.

Проблема и противоречие

Классический подход к загрузке весов в Kubernetes использует init-контейнер `storage-initializer`, который скачивает файлы из внешнего репозитория (HuggingFace, Ollama, ModelScope) в том `emptyDir`, после чего основной runtime-контейнер загружает эти веса в GPU-память. При горизонтальном масштабировании каждая новая реплика повторяет загрузку заново, не используя данные, уже скачанные другими репликами или оставшиеся на диске ноды от предыдущих запусков.

Масштаб проблемы нагляден на конкретном примере. Предположим, что burst-событие порождает 10 реплик инференса для модели Llama 3 8B с весами объёмом ≈ 15 ГБ. При использовании `emptyDir`-подхода каждая реплика независимо скачивает модель из HuggingFace Hub:

$$V_{\text{total}} = N \times S_{\text{model}} = 10 \times 15 \text{ ГБ} = 150 \text{ ГБ}$$

Это 150 ГБ внешнего трафика за одно burst-событие. При типичной ширине канала 1 Гбит/с (125 МБ/с) каждая реплика тратит $15,000/125 \approx 120 \text{ с} \approx 2 \text{ мин}$ на загрузку. Все 10 реплик стартуют с задержкой около 2 минут, конкурируя

за один и тот же канал к внешнему репозиторию, что на практике увеличивает реальное время ещё в 2–3 раза. Суммарная нагрузка на внешний канал составляет 150 ГБ — тогда как при наличии кэша достаточно загрузить модель один раз и распределить чанки внутри кластера.

Существующий паллиативный подход — NFS-хранилище — устраняет повторные загрузки из внешнего репозитория: первый под скачивает модель, остальные читают из общей директории. Однако NFS вводит центральную точку отказа (SPOF, Single Point of Failure) и bottleneck пропускной способности: при одновременном чтении десяти репликами через один NFS-сервер сеть и диск сервера становятся узким местом. Деградация или недоступность NFS-сервера делает недоступными все сервисы инференса.

Таким образом, существует противоречие: бессерверное масштабирование требует быстрого старта произвольного числа реплик, тогда как существующие механизмы доставки весов либо порождают избыточный внешний трафик (`emptyDir`), либо вводят централизованное узкое место (NFS). Требуется механизм, который сохраняет преимущества `serverless`-масштабирования, но устраняет повторную загрузку уже известных кластеру весов без введения новой единственной точки отказа.

Цель работы

Целью работы является исследование и разработка архитектуры распределённого кэширования файлов моделей машинного обучения для бессерверного инференса в Kubernetes, позволяющей сократить задержку холодного старта, уменьшить нагрузку на внешние источники данных и повысить доступность системы при горизонтальном масштабировании.

Задачи работы

Для достижения поставленной цели необходимо решить следующие задачи:

- а) **Проанализировать причины холодного старта ML-моделей в Kubernetes** — исследовать зависимость задержки инициализации от размера весов, описать механизм работы `storage-initializer` и `emptyDir`, формализовать декомпозицию времени старта и применить закон Литтла для оценки нагрузки на систему.

- б) **Исследовать существующие решения** для распределённого хранения и кэширования моделей — провести сравнительный анализ Alluxio, JuiceFS, Dragonfly, CubeFS и Rook/Ceph по критериям POSIX-совместимости, накладных расходов на метаданные, зависимости от внешней инфраструктуры и применимости к serverless-инференсу.
- в) **Разработать и оценить промежуточный подход на базе NFS** с механизмами координации параллельных загрузок — исследовать файловые блокировки (`flock`), ресурс `Lease` и алгоритм `Leader Election`; описать ограничения NFS как централизованного решения.
- г) **Исследовать механизмы координации в Kubernetes** — детально проанализировать файловые блокировки (`flock`) над NFS, ресурс `Lease` из `Coordination API`, алгоритм `Leader Election` из библиотеки `client-go` и обосновать применимость каждого механизма.
- д) **Спроектировать архитектуру распределённого chunk-кэша** с локальным хранилищем на каждой `worker`-ноде — разработать трёхуровневую схему доступа: `local cache hit` → `peer cache hit` → `remote fallback`; определить протоколы взаимодействия компонентов.
- е) **Обосновать выбор Redis** в роли реестра метаданных чанков и активных `storage-agent` — исследовать `TTL-based heartbeat` как механизм `discovery`, сравнить с `gossip`-протоколом и `mDNS`, обосновать конфигурации `Redis Sentinel` и `Redis Cluster`.
- ж) **Обосновать применение FUSE** (`Filesystem in Userspace`) для предоставления `runtime`-контейнеру стандартного файлового интерфейса — проанализировать механизм `VFS`-перехватов, оценить накладные расходы `context switch` и преимущества прозрачной интеграции с любым `ML-framework`.
- и) **Сравнить Unix Domain Socket и TCP** и обосновать их роли в локальной и междодовой коммуникации — формализовать разницу в задержке и накладных расходах; обосновать применение `UDS` для канала `storage-mounter` → `storage-agent` и `TCP` для канала между агентами на разных нодах.
- к) **Реализовать прототип компонентов** `storage-agent` и `storage-mounter` — реализовать локальный `chunk-кэш` на

дисковом хранилище, FUSE-файловую систему с lazy-loading, интерфейс к HuggingFace Hub и частичную интеграцию между компонентами.

- л) **Сформировать методику оценки эффективности и надёжности** предложенной архитектуры — построить расчётную модель на базе AMAT, проанализировать сценарии отказов, выявить ограничения и определить направления дальнейшего развития.

Объект и предмет исследования

Объект исследования — системы развёртывания и масштабирования ML-инференса в Kubernetes/serverless-средах.

Предмет исследования — методы кэширования, доставки и виртуализации доступа к файлам весов ML-моделей при холодном старте.

Научная новизна и практическая значимость

Научная новизна работы состоит в следующем:

- Предложена специализированная архитектура, объединяющая FUSE-доступ, локальный chunk-кэш на дисках worker-нод, Redis-реестр метаданных и P2P-доставку чанков для сценария serverless ML-инференса в Kubernetes.
- Обосновано предпочтение Redis heartbeat перед gossip-discovery и mDNS для малых и средних кластеров с жёстким требованием к задержке на пути cold start.
- Формализовано разделение локальной (UDS) и межнодовой (TCP) коммуникации как инструмент минимизации накладных расходов при гарантии совместимости с Kubernetes networking.

Практическая значимость: снижение времени повторного старта модели за счёт попадания в локальный или соседний кэш; уменьшение нагрузки на HuggingFace Hub и внешний канал при масштабировании реплик; возможность использовать локальные диски всех worker-нод как распределённый кэш без выделенного хранилищного кластера; устранение NFS как единственной точки отказа.

Структура работы

Работа состоит из введения, пяти разделов, заключения, списка литературы и приложений.

В первом разделе проанализирована эволюция размеров ML-моделей, описан механизм холодного старта в Kubernetes и его влияние на SLA.

Второй раздел содержит сравнительный анализ существующих решений для хранения и кэширования моделей и обоснование необходимости специализированной разработки.

В третьем разделе описан промежуточный NFS-этап с алгоритмами координации загрузок, его преимущества и ограничения.

Четвёртый раздел посвящён основной разработке — P2P/FUSE-архитектуре с описанием компонентов `storage-agent`, `storage-mounter` и Redis-реестра.

Пятый раздел содержит методику оценки, расчётную модель задержки, ожидаемые результаты сравнения и анализ ограничений.

1 ПРОБЛЕМА ХОЛОДНОГО СТАРТА ML-MODEЛЕЙ В БЕССЕРВЕРНОМ ИНФЕРЕНСЕ

Настоящий раздел посвящён обоснованию актуальности проблемы холодного старта в системах бессерверного инференса моделей машинного обучения. Рассматривается эволюция архитектур и размеров ML-моделей, показывающая, что объём весовых файлов вырос от единиц мегабайт до сотен гигабайт. Раскрывается механизм каждого этапа холодного старта в Kubernetes, обосновывается, почему классическая схема с `init`-контейнером и томом `emptyDir` неэффективно использует уже загруженные данные. Оцениваются последствия для соблюдения SLA и пользовательского опыта с применением закона Литтла и вероятностной модели холодного старта. Формулируются функциональные и нефункциональные требования к системе оптимизации.

1.1 Эволюция размеров моделей машинного обучения

1.1.1 От компактных сетей к масштабным языковым моделям

На раннем этапе развития глубокого обучения доминировали сверточные нейронные сети (CNN), ориентированные преимущественно на задачи компьютерного зрения. Прорывная работа Крижевского, Суцкевера и Хинтона представила модель AlexNet в 2012 году: сеть насчитывала 60 миллионов параметров, а объём её весовых файлов в 32-битном формате составлял около 233 МБ [8]. При типичной для того времени пропускной способности сети порядка 100 Мбит/с такой объём передавался за несколько секунд и не создавал значимых инфраструктурных проблем. Параллельно развивались рекуррентные нейронные сети (RNN) и их разновидности LSTM и GRU для задач обработки последовательностей, однако их размеры также оставались в пределах сотен мегабайт.

Качественный переход произошел в 2017 году с публикацией архитектуры Transformer. Механизм самовнимания (self-attention) обеспечил возможность эффективно обрабатывать длинные контекстные зависимости и параллелизовать обучение, что сделало Transformer доминирующей архитектурой для задач обработки естественного языка [1]. Вместе с этим значительно выросли и вычислительные требования.

Модель BERT Base (2018) с 110 миллионами параметров занимала около 440 МБ в 32-битном формате; версия BERT Large содержала 340 миллионов параметров и требовала порядка 1.4 ГБ [1]. Уже на этом этапе загрузка весов из удалённого хранилища начинала ощутимо влиять на задержку инициализации сервиса.

1.1.2 Экспоненциальный рост весов языковых моделей

Выход GPT-3 в 2020 году ознаменовал качественный скачок: 175 миллиардов параметров потребовали около 350 ГБ дискового пространства для хранения весов в 16-битном формате [9]. Для загрузки такого объёма по каналу 10 Гбит/с требуется около 280 секунд — почти пять минут только на передачу данных. В реальных условиях с конкурентными запросами из других подов это время возрастает существенно.

Тенденция к открытым моделям, начавшаяся с выпуска семейства Llama компании Meta, расширила доступ исследователей и производственных команд к крупным моделям. Llama 3 (2024) включает варианты с 8, 70 и 405 миллиардами параметров; расчётный объём основных весов модели Llama 3 70B в формате FP16 составляет около 140 ГБ [2].

Таблица 1 – Расчётный объём весов ключевых ML-моделей в формате FP16

Модель	Год	Архитектура	Параметры	Вес (FP16)	Влияние
AlexNet	2012	CNN	60 млн	≈0.12 ГБ	Незначительное
BERT Base	2018	Transformer	110 млн	≈0.22 ГБ	Малое
GPT-2 XL	2019	Transformer	1.5 млрд	≈3 ГБ	Умеренное
T5-11B	2020	Transformer	11 млрд	≈22 ГБ	Существенное
GPT-3	2020	Transformer	175 млрд	≈350 ГБ	Критическое
LLaMA 1 7B	2023	Transformer	6.7 млрд	≈13.4 ГБ	Существенное
Llama 2 70B	2023	Transformer	70 млрд	≈140 ГБ	Критическое
Falcon 180B	2023	Transformer	180 млрд	≈360 ГБ	Критическое
Llama 3 8B	2024	Transformer	8 млрд	≈16 ГБ	Существенное
Llama 3 70B	2024	Transformer	70 млрд	≈140 ГБ	Критическое
Mixtral 8×22B	2024	MoE	141 млрд	≈282 ГБ	Критическое
DeepSeek V2	2024	MoE	235.7 млрд	≈472 ГБ	Критическое
GLM-4.5	2025	MoE	358.3 млрд	≈717 ГБ	Критическое
DeepSeek V4 Pro	2026	MoE	861.6 млрд	≈1.72 ТБ	Критическое

Значения в таблице получены как произведение числа параметров на два байта, то есть описывают только основные тензоры в FP16 и используют десятичный гигабайт (10^9 байт). Фактический размер репозитория зависит от формата сериализации, разбиения на файлы и служебных данных. Для Mixtral 8×22B приведены все 141 млрд параметров, хотя на одном токене

активируется 39 млрд. Число параметров приведено по первичным публикациям и карточкам моделей [1; 13; 14; 9; 15; 16; 3; 2; 17; 10; 11; 12].

Таблица 1 демонстрирует, что за период с 2018 по 2026 год расчётный объём весов ведущих моделей вырос от сотен мегабайт до терабайт — почти на четыре порядка. Если для BERT Base загрузка занимала секунды, то для DeepSeek V4 Pro при той же пропускной способности сети она может занимать часы. Именно это изменение масштаба превращает загрузку весов из тривиальной операции в доминирующий компонент задержки холодного старта.




Рисунок 1 – Монотонная последовательность отобранных ML-моделей с возрастающим расчётным объёмом основных весов в FP16, 2018–2026 (логарифмическая шкала). График иллюстрирует рост выбранной последовательности, а не утверждает, что каждый выпуск соответствующего года крупнее всех других моделей.

1.1.3 Законы масштабирования как движущая сила роста

Рост числа параметров подчиняется так называемым законам масштабирования (scaling laws). Эмпирически установлено, что качество языковых моделей, измеряемое кросс-энтропийными потерями, улучшается в

степенной зависимости от трёх факторов: объёма параметров модели, размера обучающего набора данных и доступных вычислительных ресурсов [9]. Из этих законов следует устойчивый технологический стимул к дальнейшему увеличению масштаба: большие модели достигают того же уровня качества с меньшим числом шагов обучения и могут демонстрировать способности, не наблюдаемые у меньших моделей.

Параллельно с ростом параметров развивается концепция «плотности возможностей» (capability density) [4]: компактные модели, такие как Mistral 7B и семейство Phi-3, достигают результатов, сопоставимых с более крупными аналогами, благодаря качественным обучающим данным и архитектурным оптимизациям. Однако даже модели в диапазоне 7–70 млрд параметров требуют примерно от 13 до 140 ГБ для хранения основных весов в FP16 — объёмов, принципиально меняющих характер инфраструктурной задачи.

Таким образом, рост размеров ML-моделей является устойчивой долгосрочной тенденцией, а значит, проблема загрузки весов при холодном старте будет лишь обостряться с течением времени.

1.2 Механизм холодного старта в Kubernetes

1.2.1 Декомпозиция задержки холодного старта

При развёртывании ML-инференса в Kubernetes каждый новый инстанс сервиса проходит ряд последовательных фаз. Суммарная задержка холодного старта формализуется следующим образом:

$$T_{\text{start}} = T_{\text{schedule}} + T_{\text{pull}} + T_{\text{unpack}} + T_{\text{init}} + T_{\text{download}} + T_{\text{load}}, \quad (1)$$

где T_{schedule} — время планировщика Kubernetes для назначения пода на конкретную ноду; T_{pull} — загрузка образа контейнера из реестра; T_{unpack} — декомпрессия и распаковка слоёв образа на диск; T_{init} — выполнение init-контейнера (в том числе storage-initializer); T_{download} — скачивание весов модели из внешнего репозитория; T_{load} — загрузка весов из файловой системы в оперативную память и GPU-видеопамять.

Каждое слагаемое вносит самостоятельный вклад в суммарную задержку. Рассмотрим их характеристики и причины, по которым традиционная схема не

позволяет эффективно сократить наиболее затратные фазы.

1.2.2 Фаза планирования: T_{schedule}

Планировщик Kubernetes анализирует доступные ноды с учётом запрошенных ресурсов (CPU, память, GPU), ограничений через nodeSelector и tolerations, правил affinity и topologySpreadConstraints. При загруженном кластере или ожидании освобождения GPU-слота эта фаза может занимать от долей секунды до нескольких минут. Поскольку планировщик не учитывает наличие кэшированных весов модели на ноде, он может назначить под на ноду без нужных данных, вынуждая к их повторной загрузке.

1.2.3 Фазы загрузки и распаковки образа: $T_{\text{pull}} + T_{\text{unpack}}$

Образ контейнера для ML-инференса включает среду выполнения языка, фреймворк (PyTorch, TensorFlow), CUDA-библиотеки и вспомогательные зависимости. Для типичного контейнера с vLLM или Triton Inference Server размер образа может составлять 15–25 ГБ. Загрузка по каналу 10 Гбит/с занимает ориентировочно 12–20 секунд для передачи данных, однако реальное время больше из-за последовательного характера протокола реестра контейнеров: слои образа обычно скачиваются без полноценного параллелизма [7].

После скачивания каждый слой образа декомпрессируется из формата gzip или zstd и записывается на диск. Эта операция CPU-интенсивна: декомпрессия 20 ГБ образа может занять от трёх до восьми минут. Механизм Copy-on-Write, используемый большинством драйверов хранения контейнеров (overlay2, fuse-overlayfs), добавляет накладные расходы при последующем доступе к файлам внутри образа.

1.2.4 Фаза init-контейнера: T_{init}

Классическая схема развёртывания ML-инференса в Kubernetes предполагает использование init-контейнера (storage-initializer), который запускается до основного runtime-контейнера. Его задача — скачать файлы весов модели из внешнего хранилища (HuggingFace Hub, S3, GCS) и записать их в том типа emptyDir, разделяемый с основным контейнером.

Принципиальная схема взаимодействия выглядит следующим образом:

планировщик назначает под на ноду, после чего инициализируется том `emptyDir` на локальном диске этой ноды. Затем запускается `init`-контейнер `storage-initializer`, который последовательно скачивает файлы весов и записывает их в смонтированный `emptyDir`. После успешного завершения `init`-контейнера запускается `runtime`-контейнер (`vLLM`, `TGI`, `Triton`), который считывает файлы из `emptyDir` и загружает их в GPU-память.

1.2.5 Фаза загрузки весов из репозитория: T_{download}

Компонент T_{download} является наиболее критичным с точки зрения зависимости от размера модели. При линейном росте объёма весов это слагаемое растёт пропорционально. Для Llama 3 8B (около 16 ГБ) при канале 1 Гбит/с без конкуренции загрузка занимает ориентировочно 128 секунд; для Llama 3 70B (около 140 ГБ) — уже порядка 1120 секунд, то есть около 19 минут [7].

Ключевая особенность проблемы состоит в том, что при масштабировании до N реплик на разных нодах внешний репозиторий получает N независимых запросов на один и тот же набор файлов. Каждый `init`-контейнер выполняет полную загрузку, игнорируя тот факт, что те же данные могут уже присутствовать на соседних нодах кластера.

1.2.6 Ограничения схемы с `emptyDir`

Том `emptyDir` привязан к жизненному циклу пода и физически размещается на диске конкретной ноды. При завершении или перепланировании пода данные в `emptyDir` безвозвратно удаляются. Следствием является отсутствие механизма разделения данных между репликами на одной ноде: при масштабировании к двум репликам на одном узле каждая из них независимо скачивает полный набор весов. Отсутствует и возможность передачи уже загруженных данных между нодами кластера, что исключает локальное повторное использование при перепланировании подов.

Важно разграничить два типа повторной загрузки. Первый — внутринодовая избыточность: несколько подов на одной ноде, работающих с одной и той же моделью, независимо скачивают и хранят идентичные веса на одном диске. Второй — межнодовая избыточность: если модель уже загружена на соседней ноде, схема с `emptyDir` не предоставляет никакого

механизма для получения этих данных без повторного обращения во внешний репозиторий. При масштабировании системы до N реплик, распределённых по M нодам, возникает до N независимых операций загрузки одного и того же содержимого, что создаёт кратную нагрузку на канал до внешнего репозитория и увеличивает операционные расходы.

1.2.7 Фаза загрузки в GPU-память: T_{load}

После того как файлы весов оказались в `emptyDir`, runtime-контейнер (vLLM, TGI, Triton) считывает их с диска и загружает в GPU-память. Для Llama 3 8B эта операция занимает ориентировочно 60–120 секунд; для крупных моделей — несколько минут. Кроме того, некоторые inference-движки, в частности vLLM, выполняют компиляцию графа CUDA и профилирование KV-кэша, что дополнительно увеличивает T_{load} [7].

1.2.8 Итоговый характер задержки

Для типичного контейнера с моделью Llama 3.1 8B суммарная задержка холодного старта на чистом узле складывается ориентировочно следующим образом: $T_{\text{pull}} + T_{\text{unpack}} \approx 5\text{--}8$ мин; $T_{\text{download}} \approx 2\text{--}5$ мин; $T_{\text{load}} \approx 1\text{--}3$ мин. Итоговое время в зависимости от конфигурации сети и дисков может превышать 10–15 минут [7].

При этом задержка масштабируется нелинейно: при переходе от 8B к 70B параметров T_{download} возрастает пропорционально размеру весов, тогда как T_{load} дополнительно зависит от скорости шины памяти GPU и конкретного inference-движка.

1.3 Влияние холодного старта на SLA, пользовательский опыт и стоимость

1.3.1 SLA и метрики задержки

Соглашение об уровне обслуживания (SLA) для интерактивных AI-сервисов, как правило, регламентирует задержку на перцентилях P95 и P99, а также специфические для генеративных моделей метрики: TTFT (Time to First Token — время до первого токена) и TPS (Tokens Per Second — скорость генерации). Для диалоговых ассистентов требования к TTFT на P95 нередко составляют от нескольких сотен миллисекунд до нескольких секунд,




Рисунок 2 – Декомпозиция задержки холодного старта для Цлата 3 8В (15 ГБ, канал 200 МБ/с). Фаза загрузки весов ($T_{\text{download}} \approx 75$ с) составляет около 80% суммарного времени ≈ 94 с.

а для голосовых систем порог ещё ниже.

Холодный старт, занимающий 10–15 минут, делает соблюдение таких требований при использовании стратегии scale-to-zero принципиально невозможным без специальных архитектурных мер. Запросы, поступившие в момент инициализации пода, вынуждены ожидать завершения всей цепочки фаз из формулы (1), что многократно нарушает целевые значения P95 и P99 latency.

1.3.2 Закон Литтла: накопление ожидающих запросов

Для количественной оценки влияния холодного старта применим закон Литтла [18]. Рассмотрим подсистему ожидания инициализации подов как стационарную систему массового обслуживания. Если L_{wait} — среднее число запросов, находящихся в состоянии ожидания завершения холодного старта, λ — интенсивность входящих запросов в период масштабирования, а W_{cold} — среднее время холодного старта, то:

$$L_{\text{wait}} = \lambda \cdot W_{\text{cold}}. \quad (2)$$

Из формулы (2) следует фундаментальный вывод: при $\lambda = 10$ запр./с и $W_{\text{cold}} = 600$ с (10 мин) в очереди единовременно накапливается $L_{\text{wait}} = 6000$ ожидающих запросов. Каждый из них занимает соединение и ресурсы

API-шлюза, что при достижении порогов ограничения по соединениям приводит к отказу в обслуживании.

Закон Литтла носит универсальный характер: он не зависит от распределения времён поступления запросов и от внутренней структуры системы массового обслуживания [18]. Из уравнения (2) прямо следует, что уменьшение W_{cold} в k раз пропорционально уменьшает число ожидающих запросов L_{wait} . Это делает сокращение времени холодного старта первоочередной задачей при проектировании масштабируемого ML-инференса.

1.3.3 Вероятность холодного старта при стратегии scale-to-zero

В бессерверных системах с автомасштабированием до нуля применяется механизм keep-alive: реплика сервиса поддерживается в активном состоянии в течение времени T_{keep} после последнего запроса, после чего освобождается. Если поток входящих запросов к конкретной модели описывается пуассоновским процессом с интенсивностью λ , то вероятность холодного старта для произвольного запроса определяется формулой [18]:

$$P_{\text{cold}} = e^{-\lambda \cdot T_{\text{keep}}}, \quad (3)$$

где T_{keep} — время поддержания реплики в активном состоянии после последнего запроса.

При малой нагрузке $\lambda \rightarrow 0$, и $P_{\text{cold}} \rightarrow 1$: практически каждый запрос инициирует холодный старт. Это характерно для длинного «хвоста» редко используемых специализированных моделей. Обратно, при высокой нагрузке $\lambda \rightarrow \infty$, и $P_{\text{cold}} \rightarrow 0$: реплики постоянно активны и к ним поступают запросы до истечения keep-alive.

Из формулы (3) следует, что при фиксированном целевом SLA на максимально допустимую вероятность холодного старта $P_{\text{cold}} \leq \varepsilon$ требуемое время поддержания реплики определяется как:

$$T_{\text{keep}} \geq -\frac{\ln \varepsilon}{\lambda}. \quad (4)$$

Для модели с $\lambda = 0.01$ запра./с и допустимым $\varepsilon = 0.05$ (5% вероятность холодного старта) получаем $T_{\text{keep}} \geq 299$ с, то есть около 5 минут. За это время

простаивающая GPU потребляет энергию и занимает слот, за который взимается плата — при типичной стоимости GPU-инстанса это превращается в значительную статью операционных расходов.

1.3.4 Дилемма scale-to-zero и over-provisioning

Из приведённого анализа вытекает фундаментальная дилемма, с которой сталкиваются операторы ML-платформ. Стратегия scale-to-zero обеспечивает оптимальное использование ресурсов в периоды низкой нагрузки, однако при высоком W_{cold} делает невозможным соблюдение SLA на задержку первого токена.

Альтернатива — over-provisioning, постоянное поддержание пула «тёплых» реплик — устраняет задержку, но аннулирует экономическое преимущество бессерверной модели. Для модели, которая обрабатывает в среднем один запрос в час, постоянное удержание одной активной реплики с GPU-ускорителем создаёт крайне низкую утилизацию оборудования и высокую удельную стоимость обработки запроса.

Оптимальным является третий путь: снижение W_{cold} до уровня, при котором допустимо использовать небольшой keep-alive или даже полный scale-to-zero без критических нарушений SLA. Если холодный старт занимает 30 секунд вместо 10 минут, то допустимое время ожидания первого запроса переходит в категорию приемлемых задержек для многих производственных сценариев.

Таблица 2 иллюстрирует ориентировочный вклад различных компонентов в суммарную задержку холодного старта для модели с 8 и 70 миллиардами параметров при типичных конфигурациях. Следует подчеркнуть, что приведённые значения носят оценочный характер и существенно зависят от пропускной способности сети, производительности дискового ввода-вывода и конкретного inference-движка.

Из таблицы 2 видно, что при переходе от 8B к 70B параметров компоненты T_{download} и T_{load} вносят наибольший вклад в прирост суммарной задержки. Именно на эти компоненты должны быть направлены основные архитектурные оптимизации.

Таблица 2 – Ориентировочный вклад фаз холодного старта (оценочные данные)

Фаза	Типичная длительность		Зависимость от размера модели
	8B модель	70B модель	
T_{schedule} (планирование)	5–30 с	5–30 с	Нет
T_{pull} (загрузка образа)	2–5 мин	2–5 мин	Слабая
T_{unpack} (распаковка)	2–4 мин	2–4 мин	Слабая
T_{download} (загрузка весов)	2–4 мин	15–25 мин	Линейная
T_{load} (в GPU-память)	1–2 мин	5–10 мин	Линейная
T_{start} (итого)	7–15 мин	29–44 мин	Значимая

1.3.5 Влияние на пользовательский опыт

С точки зрения восприятия пользователем задержка свыше 3 секунд при обращении к веб-сервису существенно снижает вероятность продолжения взаимодействия. Для голосовых ассистентов и интерактивных чат-ботов практически любая задержка первого токена сверх 2–3 секунд воспринимается негативно. Холодный старт ML-сервиса, длящийся несколько минут, делает продукт практически непригодным к использованию в периоды низкой нагрузки при стратегии scale-to-zero. Это вынуждает продуктовые команды выбирать между ухудшением UX и значительными дополнительными затратами на инфраструктуру.

1.4 Требования к системе оптимизации холодного старта

На основании проведённого анализа механизма холодного старта, его количественных характеристик и экономических последствий сформулированы следующие требования к системе оптимизации.

1.4.1 Функциональные требования

ФТ-1. Минимизация задержки первого чтения данных модели. Система должна предоставлять первые байты данных модели в наиболее короткие сроки, не дожидаясь полной загрузки модели из внешнего источника. Для этого необходима поддержка потоковой или ленивой загрузки с возможностью начать инференс до полного завершения скачивания.

ФТ-2. Повторное использование уже загруженных весов. Если файлы модели или их фрагменты уже присутствуют на дисках узлов кластера, новые

реплики должны получать данные из этого локального или соседнего источника без обращения к внешнему репозиторию. Повторная загрузка идентичных байт из интернета при наличии их в кластере недопустима.

ФТ-3. Прозрачность для ML-runtime. Сервисы vLLM, TGI, Triton Inference Server и аналогичные не должны требовать модификации: они должны видеть обычный файловый путь в файловой системе и работать со стандартными POSIX-операциями чтения. Переход на новую систему не должен нарушать совместимость с существующими runtime-окружениями.

ФТ-4. Поддержка больших файлов весов. Система должна корректно работать с отдельными файлами весов размером от сотен мегабайт до нескольких сотен гигабайт, включая формат safetensors и бинарные форматы PyTorch. Обязательна поддержка произвольного доступа по смещению (range reads), характерного для ленивой загрузки.

ФТ-5. Горизонтальное масштабирование. Производительность системы не должна деградировать при добавлении новых worker-нод и увеличении числа одновременно запущенных реплик инференса. Добавление узлов должно линейно увеличивать суммарный объём локального кэша, доступного всему кластеру.

ФТ-6. Локальность данных и приоритет источников. При обслуживании запроса на данные должен соблюдаться следующий приоритет источников: первый — локальный диск той же ноды; второй — диски соседних нод кластера по внутренней сети; третий — внешний репозиторий модели. Такая иерархия минимизирует сетевой трафик и задержки.

1.4.2 Нефункциональные требования

НТ-1. Отказоустойчивость при падении узла. Выход одной или нескольких worker-нод из строя не должен делать модель полностью недоступной, при условии что её данные присутствуют на других нодах или доступны через fallback на внешний репозиторий. Система должна корректно обнаруживать недоступность узла и переключаться на альтернативный источник.

НТ-2. Устранение единой точки отказа (SPOF). Архитектура не должна содержать единственного центрального компонента, недоступность которого делает систему нефункциональной. Это требование непосредственно исключает использование одного NFS-сервера в качестве единственного

хранилища весов.

НТ-3. Контролируемые накладные расходы. Объём метаданных и управляющего трафика (регистрация чанков, heartbeat-сигналы, запросы к реестру) не должен создавать значимой нагрузки на сеть кластера или перегружать реестр метаданных. Накладные расходы на один запрос данных должны составлять пренебрежимо малую долю по сравнению с полезной нагрузкой.

НТ-4. Совместимость с Kubernetes. Все компоненты системы должны развёртываться как стандартные ресурсы Kubernetes — DaemonSet для агентов на каждой ноде, Deployment для управляющих компонентов, стандартные PVC/PV для постоянного хранения — без модификации ядра операционной системы, kubelet или компонентов control plane.

Совокупность сформулированных требований определяет целевые свойства архитектуры, которая должна обеспечивать приоритет локальных данных, прозрачность для runtime-сред и отказоустойчивость без центральной точки отказа.

1.5 Выводы по разделу

Проведённый анализ позволяет сформулировать следующие выводы.

Рост размеров ML-моделей за период с 2012 по 2024 год на три-четыре порядка превратил холодный старт из второстепенной инфраструктурной задержки в архитектурный приоритет. Компоненты T_{download} и T_{load} из формулы (1) доминируют в суммарном времени инициализации и напрямую определяются наличием локально кэшированных весов.

Применение закона Литтла (2) показывает, что линейное снижение W_{cold} пропорционально снижает число ожидающих запросов L_{wait} , что критически важно при burst-масштабировании. Формула (3) демонстрирует, что для редко запрашиваемых моделей вероятность холодного старта стремится к единице вне зависимости от политики keep-alive, что оправдывает применение архитектурных механизмов ускорения.

Классическая схема с emptyDir не переиспользует уже загруженные веса между репликами и нодами, что при масштабировании приводит к N -кратному увеличению нагрузки на внешний репозиторий. Сформулированные функциональные и нефункциональные требования определяют необходимые свойства системы: локальность данных,

прозрачность для ML-runtime, горизонтальная масштабируемость, отказоустойчивость без SPOF.

Центральный вывод раздела состоит в том, что ускорять необходимо не вычислительную фазу инференса, а подготовительную: доставку, кэширование и представление весов модели приложению. Это требует специализированной архитектуры хранения данных, ориентированной на локальность, P2P-передачу между нодами и прозрачный файловый интерфейс для runtime-окружений.

2 АНАЛИЗ СУЩЕСТВУЮЩИХ РЕШЕНИЙ ДЛЯ ХРАНЕНИЯ И КЭШИРОВАНИЯ МОДЕЛЕЙ

В данном разделе исследуются архитектуры и свойства наиболее распространённых систем распределённого хранения и кэширования, рассматриваемых в качестве кандидатных решений для задачи ускорения холодного старта ML-инференса в Kubernetes. Для каждого решения проводится анализ применимости к сценарию бессерверного инференса: определяется, в какой мере система устраняет повторные загрузки весов, обеспечивает локальность данных на worker-нодах и сохраняет прозрачный файловый интерфейс для runtime-контейнера. На основе анализа формулируется обоснование разработки специализированного решения.

2.1 Критерии сравнения решений

Чтобы сравнение систем было обоснованным и воспроизводимым, необходимо зафиксировать критерии, непосредственно вытекающие из требований, сформулированных в разделе 1. Каждый критерий отражает конкретный аспект задачи ускорения холодного старта.

Задержка при холодном старте определяет, насколько система способна уменьшить время до первого доступного байта весов модели. Ключевой характеристикой здесь является поддержка ленивой загрузки (lazy loading) или чтения по требованию: runtime-контейнер должен иметь возможность стартовать и обращаться к отдельным фрагментам файла ещё до его полной передачи.

Поддержка Kubernetes означает наличие официального механизма развёртывания в контейнерной среде: CSI-драйвера, Helm-чарта или Kubernetes Operator. Отсутствие этих инструментов существенно увеличивает операционную сложность интеграции.

Локальный кэш на нодe — возможность хранить горячие данные непосредственно на дисках worker-нод вблизи compute-ресурсов, что обеспечивает минимальную latency при повторном чтении. Решения, хранящие данные только в центральном хранилище, не позволяют избавиться от сетевого хопа при каждом обращении.

P2P-доставка отражает способность системы передавать данные между worker-нодами без обращения к центральному источнику, тем самым

распределяя нагрузку и ускоряя одновременное масштабирование большого числа реплик инференса.

FUSE/POSIX-интерфейс оценивает, предоставляет ли система runtime-контейнеру стандартный файловый путь, не требующий изменений в ML-фреймворке. Наличие POSIX-семантики позволяет vLLM, Triton и аналогичным инструментам работать без модификации кода.

Отказоустойчивость характеризует поведение системы при выходе из строя отдельных узлов: существуют ли механизм репликации данных и автоматический fallback на альтернативный источник.

Наличие единой точки отказа (SPOF) указывает, имеется ли в архитектуре компонент, отказ которого делает недоступными все данные. Это критически важно для сред с требованиями высокой доступности.

Зависимость от внешнего объектного хранилища определяет, является ли object storage обязательным звеном в пути чтения. Обязательное обращение к S3/GCS при каждом промахе кэша существенно увеличивает latency и создаёт зависимость от внешней инфраструктуры.

Прозрачность для runtime оценивает, насколько решение скрывает распределённую природу данных от приложения. Идеальная прозрачность означает, что ML-контейнер «видит» обычную директорию с файлами модели.

Сложность эксплуатации суммирует требования к компетенциям команды и инфраструктурным зависимостям. Решения с высокой сложностью неприемлемы для небольших платформ без выделенного SRE-отдела.

Применимость к serverless cold start является интегральным критерием: насколько хорошо решение адаптировано к сценарию эфемерных подов, работающих с крупными бинарными файлами весов, при жёстких ограничениях на время инициализации.

Перечисленные критерии используются в сравнительной таблице 3 и в итоговом обосновании разработки специализированного решения.

2.2 Alluxio

Alluxio (ранее Tachyon) — виртуальная распределённая файловая система (Virtual Distributed File System, VDFS), выступающая слоем оркестрации данных между вычислительными фреймворками и системами постоянного хранения (Amazon S3, HDFS, NFS и другими) [19]. Система

разработана в Калифорнийском университете в Беркли и нашла применение в крупномасштабных аналитических и ML-рабочих нагрузках.

Архитектура

Alluxio строится по модели Master/Worker/Client. *Ведущий узел* (Leading Master) управляет глобальными метаданными: деревом inode, распределением блоков и ёмкостью рабочих узлов. Все транзакции файловой системы записываются в распределённый журнал для обеспечения восстановления состояния при сбое. Для обеспечения высокой доступности (HA) рядом с ведущим мастером работают несколько резервных мастеров, непрерывно синхронизирующихся через журнал и готовых принять управление при отказе основного.

Worker-узлы управляют локальными ресурсами хранения (RAM, SSD, HDD), выделенными под кэш Alluxio. Данные хранятся в виде блоков. При заполнении ёмкости применяются политики вытеснения (LRU и аналоги). Worker-узлы также выполняют операции с базовым хранилищем (Under File System, UFS): при первом обращении к данным они кэшируют блоки локально, снижая нагрузку на UFS при последующих чтениях.

Client предоставляет приложению шлюз к кластеру Alluxio. Он взаимодействует с Master для операций с метаданными и с Worker для чтения и записи данных. Поддерживаются нативный Java API, REST, HDFS API и S3-совместимый API. Важно отметить, что клиент Alluxio никогда не обращается напрямую к базовому хранилищу: данные всегда передаются через Worker-узлы [19].

Интеграция с Kubernetes реализована через Helm-чарты и Alluxio Operator, который автоматизирует развёртывание, настройку и управление жизненным циклом кластера Alluxio поверх Kubernetes [20]. Alluxio поддерживает монтирование через FUSE (Alluxio POSIX API), что обеспечивает прозрачный доступ для приложений через стандартный файловый интерфейс.

В Enterprise-версии архитектура мастера эволюционировала в сторону децентрализации: владение метаданными распределяется между Worker-узлами через согласованное хеширование, что устраняет централизованный мастер как узкое место и позволяет обходить его при чтении данных.

Преимущества

Alluxio обеспечивает высокую производительность за счёт приоритетного кэширования в оперативной памяти (memory-first tiered architecture). Унифицированное пространство имён (Unified Namespace) позволяет монтировать разнородные хранилища в единую логическую файловую систему, что актуально для платформ с несколькими объектными хранилищами. Поддержка локальности данных выгодна для ML-нагрузок: когда модельные данные кэшируются на ноде, где запущен инференс, задержка чтения снижается до уровня локального диска.

Недостатки

Первый существенный недостаток — *сложность эксплуатации*. Даже при наличии Kubernetes Operator настройка HA-конфигурации мастеров, управление eviction-политиками, диагностика утечек памяти в Worker-узлах и оптимизация распределения блоков требуют глубоких знаний архитектуры системы. Операционная нагрузка несопоставима с задачей кэширования весов модели.

Второй недостаток — *высокое потребление памяти*. Alluxio является memory-centric системой: для достижения декларируемой производительности Worker-узлы должны располагать значительным объёмом оперативной памяти. При кэшировании нескольких больших моделей (десятки гигабайт каждая) потребности в памяти конкурируют с самим GPU-инференсом.

Третий недостаток — *модель лицензирования*. Ключевые функции для производственных ML-сред: децентрализованная архитектура, расширенные политики кэширования и продвинутое AI/ML-оптимизации — доступны только в Enterprise Edition [21]. Стоимость не публикуется и определяется индивидуально, что создаёт финансовую неопределённость.

Четвёртый недостаток — *несовместимость с serverless-подами*. Клиент Alluxio предполагает наличие состояния и устойчивого соединения с кластером. В эфемерных подах Kubernetes каждая инициализация клиента добавляет задержку к холодному старту, а данные, кэшированные по запросу короткоживущего пода, могут быть вытеснены прежде, чем повторно использованы.

Вывод по Alluxio

Alluxio технически близок к задаче: он обеспечивает кэширование данных с локальностью и поддерживает FUSE-монтирование. Однако он представляет собой тяжёлый data orchestration layer общего назначения, предназначенный для аналитики и распределённого ML-обучения. Для узкой задачи chunk-кэширования весов модели в serverless-инференсе это архитектурно и операционно избыточное решение.

2.3 JuiceFS

JuiceFS — высокопроизводительная распределённая файловая система с POSIX-совместимым интерфейсом, ориентированная на облачные среды [22]. Community Edition распространяется под лицензией Apache 2.0. Система нашла применение в ML-платформах благодаря нативной интеграции с Kubernetes и возможности использовать уже существующие объектные хранилища как backend.

Архитектура

Фундаментальной особенностью JuiceFS является *строгое разделение данных и метаданных*. Архитектура включает три компонента.

Metadata Engine хранит всю информацию о файловой системе: имена файлов, права доступа, временные метки, структуру директорий и, что критически важно, отображение файлов на физические блоки данных. Community Edition поддерживает несколько бэкендов: Redis, TiKV, PostgreSQL, MySQL/MariaDB [23]. Выбор Redis обеспечивает минимальные задержки (порядка миллисекунд) за счёт хранения в оперативной памяти, TiKV обеспечивает горизонтальную масштабируемость для платформ с миллиардами объектов.

Object Storage хранит содержимое файлов в виде блоков. При записи файл логически делится на чанки по 64 МБ, каждый из которых при сбросе (flush) разбивается на блоки по 4 МБ, параллельно загружаемые в объектное хранилище [23]. JuiceFS поддерживает Amazon S3, MinIO, Google Cloud Storage и другие S3-совместимые системы. В самом объектном хранилище исходные файлы не представлены: там хранятся пронумерованные блоки, а их связь с файловой иерархией поддерживается через Metadata Engine.

Клиент JuiceFS реализует файловый интерфейс (FUSE, CSI-драйвер, S3 Gateway) и взаимодействует одновременно с Metadata Engine (для получения структуры файла и местоположения блоков) и с объектным хранилищем (для чтения и записи данных).

В Kubernetes JuiceFS развёртывается через CSI-драйвер, который реализует архитектуру с выделенным Mount Pod на каждом узле. Этот под исполняет клиент FUSE и обслуживает все application pods на узле, использующие один и тот же PVC. Такое разделение позволяет перезапускать CSI-компоненты без прерывания доступа к данным для уже запущенных приложений [24].

Кэширование на локальных дисках является ключевым механизмом ускорения: при повторном чтении одних и тех же блоков JuiceFS обслуживает запросы с локального NVMe-диска вместо обращения к объектному хранилищу. По данным разработчиков, при последовательном чтении крупных файлов с включённым локальным кэшем пропускная способность может вырасти с 4,7 ГБ/с до 13,2 ГБ/с, а задержка случайного чтения — снизиться с 29 мс до 0,3 мс [24].

Ограничения для serverless cold start

Зависимость от объектного хранилища. JuiceFS не имеет собственного слоя хранения данных и обязательно требует внешнего S3-совместимого хранилища. При промахе кэша (cache miss) клиент обращается к объектному хранилищу, задержки которого на порядок превышают задержки локального диска.

Metadata Engine как потенциальная точка отказа. При использовании Redis в качестве бэкенда метаданных и отсутствии HA-конфигурации (Redis Sentinel или Redis Cluster) отказ экземпляра Redis делает недоступной всю файловую систему, даже если объектное хранилище функционирует нормально. Настройка кластерного Redis добавляет операционную сложность.

Проблема прогрева кэша в эфемерных средах. В serverless-сценарии поды часто запускаются на «чистых» узлах, где локальный кэш пуст. В отличие от долгоживущих приложений, эфемерный под не успевает накопить полезный кэш до своего завершения. При масштабировании на новые узлы все читаемые блоки будут приходить из объектного хранилища — именно в тот момент, когда критична latency первого байта.

Накладные расходы FUSE. Реализация файловой системы в пространстве пользователя через FUSE вносит дополнительные переключения контекста при каждом файловом вызове. При большом числе мелких операций чтения это снижает эффективную пропускную способность одного потока.

Шторм монтирований при scale-out. При одновременном масштабировании на большое число новых узлов создание Mount Pod'ов для каждого узла увеличивает нагрузку на API-сервер Kubernetes и может задерживать инициализацию новых подов.

Вывод по JuiceFS

JuiceFS представляет ценный архитектурный ориентир: разделение данных и метаданных, использование Redis как быстрого metadata backend, FUSE-интерфейс — все эти идеи применены в разрабатываемой системе. Однако JuiceFS является файловой системой общего назначения с обязательной зависимостью от объектного хранилища, тогда как для решения задачи требуется специализированный cache/fetch слой с P2P-передачей чанков между нодами кластера.

2.4 Dragonfly, CubeFS и Rook/Ceph

Dragonfly

Dragonfly — P2P-система распределения файлов и контейнерных образов, разработанная Alibaba Cloud и переданная в Cloud Native Computing Foundation (CNCF) [25]. Система ориентирована на сценарии эффективного распространения крупных файлов на большое число узлов одновременно, что делает её концептуально близкой к задаче distributing весов ML-моделей.

Архитектура. Dragonfly сочетает элементы CDN и P2P. *Scheduler* является центральным компонентом: он отслеживает доступность узлов-пиров, их загрузку и местоположение данных, определяя оптимальные источники для каждого запроса. *Seed Peer* — специализированный пир, кэширующий данные и выступающий первичным источником для других пиров, особенно когда исходный сервер недоступен или перегружен. *Peer (dfdaemon)* работает на каждом узле Kubernetes как DaemonSet, перехватывает запросы на загрузку образов и файлов, перенаправляя их в P2P-сеть. При

загрузке каждый пир одновременно становится источником для других, распределяя нагрузку.

Применимость к ML-инференсу. Dragonfly хорошо зарекомендовал себя для параллельной дистрибуции образов контейнеров на сотни нод. Та же модель применима к весам ML-моделей: при первой загрузке модели на один из узлов она кэшируется и становится доступной для скачивания другими узлами через P2P-сеть вместо обращения к центральному репозиторию. Это снижает нагрузку на Hugging Face или внутренний model registry и ускоряет масштабирование.

Ограничения. Dragonfly не предоставляет стандартного FUSE/POSIX-интерфейса: система занимается доставкой файлов, но не монтированием файловой системы. Для предоставления ML-runtime доступа к весам модели через обычный файловый путь потребуется дополнительный уровень. Scheduler и Seed Peer требуют отдельного развёртывания и поддержки, увеличивая операционную нагрузку. Наличие централизованного Scheduler вводит компонент, отказ которого нарушает координацию P2P-сети, хотя фактическая доставка данных продолжается между пирами. Тем не менее Dragonfly является ближайшим по духу предшественником P2P-подхода, разработанного в данной работе: идея обмена фрагментами данных между узлами кластера вместо многократного скачивания из центрального источника лежит в основе обоих решений.

CubeFS

CubeFS — облачно-ориентированная распределённая файловая система уровня CNCF Graduated [26], разработанная JD.com. Система предоставляет унифицированное хранилище с поддержкой нескольких протоколов доступа и предназначена для высоконагруженных производственных сред.

Архитектура. CubeFS включает несколько подсистем. *Master-узлы* управляют ресурсами кластера: отслеживают состояние Meta Nodes и Data Nodes, управляют томами и обеспечивают согласованность конфигурации с использованием Raft и RocksDB. *Meta Nodes* управляют шардами метаданных (Meta Partition). Каждый шард содержит две B-Tree структуры в памяти: inode B-Tree и dentry B-Tree. Минимальная конфигурация требует трёх экземпляров. *Data Nodes* управляют шардами данных (Data Partition) и образуют репликационные группы. CubeFS поддерживает как репликацию

данных, так и Erasure Coding (через подсистему Blobstore) для более эффективного использования дискового пространства. Объектный шлюз (Object Subsystem) предоставляет S3-совместимый API.

Поддерживаемые протоколы. CubeFS поддерживает POSIX, S3 и HDFS-интерфейсы, а также CSI-драйвер для Kubernetes. Мультипротокольная поддержка делает систему гибкой для смешанных рабочих нагрузок, где различные компоненты ML-платформы используют разные интерфейсы доступа к данным.

Применимость к ML-инференсу. CubeFS обеспечивает высокую пропускную способность для крупных файлов за счёт параллелизма Data Nodes. POSIX-совместимость позволяет использовать систему для хранения и одновременного доступа к файлам весов модели из нескольких реплик инференса. Репликация данных обеспечивает отказоустойчивость при выходе из строя отдельных узлов.

Ограничения. Сложность развёртывания CubeFS сопоставима с Ceph: кластер требует управления несколькими типами узлов (Master, MetaNode, DataNode), настройки репликации, мониторинга состояния и обеспечения кворума Meta Nodes. Для небольших и средних ML-платформ операционные требования несоразмерны задаче. Кроме того, CubeFS проектировалась как система хранения общего назначения, а не как специализированный кэш для бессерверного инференса: в ней отсутствуют P2P-доставка чанков и встроенный механизм lazy loading для ML-весов.

Rook/Ceph

Rook — cloud-native оркестратор для Kubernetes, автоматизирующий развёртывание и управление распределёнными системами хранения [27]. В наиболее распространённой конфигурации Rook используется для оркестрации Ceph — одной из наиболее функционально богатых open-source-систем хранения данных.

Архитектура Ceph. Ceph предоставляет блочное (RADOS Block Device, RBD), файловое (CephFS) и объектное (RADOS Gateway, RGW) хранилище в единой системе [28]. Архитектура строится на нескольких типах демонов. *Monitor (MON)* — поддерживает главную копию cluster map и обеспечивает консенсус между узлами через алгоритм Paxos; для HA требуется не менее трёх мониторов. *Manager (MGR)* — отвечает за мониторинг, управление и

расширения (плагины). *OSD Daemon* — хранит данные на физических дисках, выполняет репликацию и проверку состояния. *Metadata Server (MDS)* — управляет метаданными CephFS и обеспечивает POSIX-совместимый доступ к файловой системе.

Децентрализованное размещение данных реализовано через алгоритм CRUSH (Controlled Replication Under Scalable Hashing), который позволяет клиентам самостоятельно вычислять местоположение данных без обращения к центральному индексу. Это устраняет масштабируемые ограничения централизованного метаданных-сервера.

CephFS в Kubernetes. Rook автоматизирует создание и управление пулами CephFS и предоставляет CSI-драйвер, поддерживающий режим доступа ReadWriteMany (RWX). Это позволяет нескольким подам одновременно монтировать один том для доступа к общим данным — актуальный сценарий для ML-инференса, где несколько реплик читают одну модель.

Ограничения. Развёртывание Ceph требует специализированных знаний: настройка пулов CRUSH, управление OSD-журналами, диагностика медленных OSD и оптимизация производительности под конкретную нагрузку создают значительный барьер для команд без опыта работы с Ceph. Минимальный production-кластер требует нескольких выделенных узлов хранения с отдельными дисками.

Ceph является универсальной production-системой хранения, а не специализированным решением для кэширования весов ML-моделей. Его возможности существенно превосходят необходимые для данной задачи, а операционные требования несоразмерны её масштабу. Для сценария бессерверного инференса, где ключевая метрика — latency первого байта при холодном старте, — Rook/Ceph обеспечивает избыточную функциональность при высокой стоимости эксплуатации.

2.5 Сравнительная таблица

Для удобства сопоставления результаты анализа сведены в таблицу 3.

Анализ таблицы 3 позволяет сформулировать следующие наблюдения. Ни одно из рассмотренных решений не удовлетворяет всем требованиям одновременно. Dragonfly наиболее близок по концепции P2P-доставки и показывает высокую применимость к serverless-сценариям, однако не

Таблица 3 – Сравнение решений для хранения и кэширования ML-моделей

Критерий	Alluxio	JuiceFS	Dragonfly	CubeFS	Rook/Ceph
Лок. кэш на ноде	Да	Да	Да	Да	Да
P2P-доставка	(RAM/SSD) Нет	(диск) Нет	(диск) Да	(диск) Нет	(OSD) Нет
FUSE/POSIX	Частично	Да	Нет	Да	Да
K8s-интеграция	Helm/ Operator	CSI	DaemonSet	CSI	(CephFS) Rook
SPOF в архитектуре	Master (OSS)	Metadata Engine	Scheduler	Master	Operator MON
Объектное хранилище	Опционально	Обязательно	Не нужно	Не нужно	(кворум) Встроено (RGW)
Сложность эксплуатации	Высокая	Средняя	Средняя	Высокая	Очень высокая
Применимость к serverless	Средняя	Низкая	Высокая	Средняя	Низкая
Лицензия	Community/ Ent.	Apache 2.0	Apache 2.0	Apache 2.0	LGPL/ Apache

предоставляет FUSE-интерфейса и требует отдельной инфраструктуры с собственным Scheduler. JuiceFS имеет POSIX-интерфейс и хорошую архитектуру метаданных, но обязательная зависимость от объектного хранилища и отсутствие P2P между нодами делают его неоптимальным для данной задачи. Alluxio и Rook/Ceph обладают богатой функциональностью, но их операционная сложность несоразмерна специализированной задаче кэширования весов. CubeFS занимает промежуточное положение: поддерживает POSIX и K8s-интеграцию, но лишена P2P-доставки и сложна в эксплуатации.

2.6 Обоснование разработки специализированного решения

Проведённый анализ демонстрирует системное несоответствие между возможностями существующих решений и требованиями задачи. Каждая из рассмотренных систем спроектирована как универсальная инфраструктура хранения данных общего назначения. Задача же данной работы принципиально уже: обеспечить быстрый локальный или междолевой доступ к фрагментам (чанкам) файлов весов ML-моделей для контейнеров бессерверного инференса в Kubernetes. Ниже приведены конкретные аргументы в пользу разработки специализированного решения.

Специализация вместо универсальности. Все рассмотренные системы обеспечивают функциональность, существенно выходящую за рамки необходимой: поддержку множественных протоколов доступа, управление

большими кластерами хранения, операции записи для приложений. Для задачи serverless-инференса нужен узкий cache/fetch слой, ориентированный на оптимизацию чтения крупных бинарных файлов по фрагментам. Дополнительная функциональность увеличивает поверхность отказов и затраты на эксплуатацию без соответствующего увеличения полезности.

Приоритет локальности данных. В идеальном случае чанк весов модели должен читаться с локального диска той же ноды, на которой запущен inference-контейнер. Это исключает сетевой хоп и обеспечивает минимальную задержку. Ни одна из рассмотренных систем не реализует явного приоритета «локальный диск -> соседняя нода -> внешний источник» в виде встроенного трёхуровневого read path для serverless-сценария.

P2P в сочетании с FUSE. Dragonfly реализует P2P-доставку, но не предоставляет POSIX-интерфейса. JuiceFS предоставляет FUSE, но не поддерживает P2P между нодами. Требуемая комбинация — P2P-доставка чанков между узлами кластера с представлением результата через стандартный файловый путь — отсутствует ни в одном из существующих решений в готовом виде.

Простая модель метаданных с TTL. Redis в роли реестра метаданных чанков обеспечивает атомарные операции, низкую задержку lookup ($O(1)$ по ключу) и встроенный механизм TTL для автоматического удаления устаревших записей о недоступных нодах. Это принципиально проще, чем поддержка полноценного Metadata Engine с журналами, репликой Raft и сложной схемой партиционирования, как в JuiceFS или CubeFS. Для кластеров малого и среднего размера (до тысяч нод) одиночный или сентинельный Redis является достаточным и значительно более управляемым решением.

Fallback без жёсткой зависимости. Специализированная система допускает ситуацию, когда нужный чанк отсутствует в кластере: в этом случае он скачивается из внешнего источника (Hugging Face или другого registry) и сохраняется в локальном кэше. Такой fallback требуется лишь при первом обращении к модели; все последующие поды получают чанк из локального или соседнего кэша. Это свойство устраняет принципиальную зависимость от объектного хранилища как обязательного звена в пути чтения, в отличие от JuiceFS.

Отказоустойчивость без центрального файлового сервера. NFS как общее хранилище, рассмотренное в разделе 3, решает задачу устранения

повторных загрузок из интернета, но создаёт центральное узкое место: все чтения крупных файлов проходят через один файловый сервер. Специализированная система использует локальные диски всех worker-нод как распределённый кэш: при отказе одной ноды чанки, хранившиеся на ней, могут быть получены от других нод или из внешнего источника. Redis с TTL автоматически удаляет устаревшие записи об отказавшем агенте. Такая модель принципиально более устойчива к частичным отказам, чем централизованный NFS.

Дополнительным аргументом является экономическая доступность: все описанные компоненты (Redis, FUSE-библиотека, Go-реализация агента) распространяются под открытыми лицензиями. Alluxio Enterprise с ключевыми функциями кэширования и Rook/Ceph с его операционными требованиями несут значительные финансовые и инфраструктурные затраты, неприемлемые для небольших ML-платформ.

2.7 Выводы по разделу

Рассмотренные решения — Alluxio, JuiceFS, Dragonfly, CubeFS и Rook/Ceph — предоставляют ценные архитектурные идеи, нашедшие отражение в разрабатываемой системе: разделение данных и метаданных (JuiceFS), P2P-дистрибуция между узлами кластера (Dragonfly), предоставление POSIX-совместимого интерфейса через FUSE (JuiceFS, CubeFS, CephFS).

Вместе с тем ни одно из существующих решений не обеспечивает требуемую комбинацию свойств: трёхуровневый read path с приоритетом локального кэша, P2P-доставку чанков между нодами и прозрачный FUSE-интерфейс для ML-runtime без обязательной зависимости от внешнего объектного хранилища и тяжёлой операционной инфраструктуры.

Это обосновывает разработку специализированной системы: lightweight chunk-кэша на локальных дисках worker-нод, сопровождаемого Redis-реестром метаданных чанков и FUSE-клиентом, обеспечивающим runtime-контейнеру стандартный файловый интерфейс. Описание промежуточного этапа — подхода на основе NFS и координации загрузок — приведено в разделе 3. Основная архитектура разрабатываемой системы описана в разделе 4.

3 ПРОМЕЖУТОЧНОЕ РЕШЕНИЕ НА БАЗЕ NFS И КООРДИНАЦИИ ЗАГРУЗОК

В данном разделе описывается промежуточный этап оптимизации системы бессерверного инференса: переход от изолированной загрузки весов модели в том `emptyDir` к использованию сетевой файловой системы NFS в качестве общего хранилища. Раскрываются недостатки исходной схемы, механизм интеграции NFS в Kubernetes через ресурсы `PersistentVolume` и `PersistentVolumeClaim`, проблемы синхронизации параллельных загрузок, особенности файловых блокировок поверх сетевых файловых систем, применение механизма `Leader Election` через `Kubernetes Lease API`, а также системные ограничения, обусловившие необходимость разработки распределённой P2P/FUSE-архитектуры.

3.1 Исходная схема: `storage-initializer` и `emptyDir`

Паттерн `init`-контейнера и жизненный цикл тома `emptyDir`

Исходная схема развёртывания модели в Kubernetes использует паттерн `init`-контейнера. Под (`pod`) содержит два контейнера: `storage-initializer`, запускаемый первым в режиме `init`, и `runtime`-контейнер, являющийся основным. `Init`-контейнер монтирует том типа `emptyDir`, запускает процесс загрузки весов модели из внешнего репозитория (`HuggingFace`, `ModelScope`, объектное S3-совместимое хранилище) и записывает файлы в смонтированный том. После успешного завершения `init`-контейнера Kubernetes запускает `runtime`-контейнер (`vLLM`, `TGI`, `Triton`), который читает веса из того же тома `emptyDir` и загружает их в GPU-память для обслуживания запросов.

Том типа `emptyDir` создаётся Kubernetes в момент планирования пода на узел и физически размещается на локальном диске этого узла, либо, при явной конфигурации, в памяти. Ключевая характеристика данного типа тома состоит в том, что его жизненный цикл жёстко привязан к жизненному циклу пода: при удалении или перепланировании пода том уничтожается вместе со всем содержимым. Том `emptyDir` не является персистентным и принципиально не разделяется между подами: каждый под получает собственную изолированную директорию.

Фундаментальный недостаток: повторные загрузки

Отсутствие разделяемого хранилища порождает фундаментальный недостаток данной схемы. При создании новой реплики, даже на той же узловой машине, каждый под выполняет полную загрузку файлов модели независимо от всех ранее запущенных подов. Если уже работающий под уже завершил загрузку той же модели, новый под этого не знает и не может воспользоваться имеющейся копией данных.

При масштабировании до N реплик внешний репозиторий получает N независимых последовательных или параллельных запросов на один и тот же набор файлов. Для современных моделей класса LLM с объёмом весов от 7 до 70 ГБ это означает:

- суммарный исходящий трафик на уровне десятков и сотен гигабайт при каждом событии масштабирования;
- время cold start каждой реплики полностью определяется скоростью загрузки из внешнего источника, а не скоростью чтения с диска;
- нагрузка на внешний канал связи возрастает пропорционально числу реплик, что может приводить к деградации пропускной способности и к превышению rate-лимитов репозитория.

Таким образом, схема `storage-initializer + emptyDir` не решает задачу cold start при масштабировании: повторные загрузки по-прежнему присутствуют, хотя и перемещены с уровня повторных запусков того же пода на уровень каждой новой реплики.

3.2 Переход к NFS как общему хранилищу

NFS и режим ReadWriteMany

Network File System (NFS) — зрелый протокол сетевого доступа к файлам, разработанный компанией Sun Microsystems и стандартизированный в версиях NFSv3 (RFC 1813) и NFSv4 (RFC 7530). В контексте Kubernetes NFS привлекателен прежде всего тем, что поддерживает режим доступа ReadWriteMany (RWX), при котором несколько подов на разных узлах кластера могут одновременно монтировать один и тот же том как для чтения, так и для записи [29]. Большинство блочных хранилищ поддерживают лишь режим ReadWriteOnce (RWO), допускающий монтирование только одним

подом, что исключает их применение для общего кэша весов моделей.

Интеграция в Kubernetes: PV и PVC

Схема использования NFS в Kubernetes предполагает создание двух ресурсов: `PersistentVolume` (PV), описывающего физическое хранилище, и `PersistentVolumeClaim` (PVC), представляющего запрос пода на использование этого хранилища. Ниже приведены примеры манифестов.

Листинг 1: `PersistentVolume` на базе NFS

```
1 apiVersion: v1
2 kind: PersistentVolume
3 metadata:
4   name: models-nfs-pv
5 spec:
6   capacity:
7     storage: 500Gi
8   volumeMode: Filesystem
9   accessModes:
10    - ReadWriteMany
11   persistentVolumeReclaimPolicy: Retain
12   nfs:
13     path: /exports/models
14     server: 10.0.1.100
```

Листинг 2: `PersistentVolumeClaim` для NFS-тома

```
1 apiVersion: v1
2 kind: PersistentVolumeClaim
3 metadata:
4   name: models-nfs-pvc
5   namespace: inference
6 spec:
7   accessModes:
8     - ReadWriteMany
9   resources:
10     requests:
11       storage: 500Gi
12   volumeName: models-nfs-pv
```

Поды, смонтировавшие этот PVC через `spec.volumes`, получают доступ к единой файловой системе, физически расположенной на

NFS-сервере. Kubernetes автоматически связывает PVC с подходящим PV при наличии совпадающих параметров ёмкости и режима доступа. Для автоматизации создания PV по запросу PVC без ручного администрирования применяется динамическое выделение ресурсов (dynamic provisioning) через внешние провизионеры, такие как *NFS Subdir External Provisioner*, которые автоматически создают поддиректории на NFS-сервере для каждого нового PVC.

Устранение повторных загрузок

Введение NFS принципиально изменяет характер загрузок: первый под, обнаруживший отсутствие модели в NFS-директории, загружает её из внешнего репозитория и записывает в общее хранилище. Все последующие поды, монтирующие тот же PVC, обнаруживают файлы уже готовыми и пропускают этап загрузки. Таким образом, при масштабировании с 1 до N реплик загрузка из внешнего источника выполняется ровно один раз, а не N раз, что устраняет ключевую неэффективность схемы `emptyDir`.

3.3 Проблема параллельного скачивания и условие гонки

Race condition при первом развёртывании

Несмотря на устранение повторных загрузок при масштабировании уже существующей модели, переход к NFS порождает новую задачу: состояние гонки (race condition) при первом развёртывании или после принудительной инвалидации кэша. В этом сценарии несколько реплик запускаются одновременно. Каждая из них на этапе инициализации проверяет директорию модели в NFS и обнаруживает её отсутствие. После этого несколько реплик независимо начинают параллельную загрузку весов по одному и тому же пути назначения.

Параллельная запись одних и тех же файлов из нескольких источников приводит к непредсказуемым последствиям: файлы могут оказаться повреждёнными вследствие чередования блоков от разных источников, директория модели может находиться в частично записанном состоянии, которое воспринимается другими подами как готовое. В результате runtime-контейнер может попытаться загрузить модель из повреждённого набора файлов, что приведёт к ошибке инициализации или некорректным

ответам модели.

Алгоритм координированной загрузки

Для решения задачи консистентности при параллельном старте разработан алгоритм координированной загрузки, основанный на сочетании файловых блокировок и атомарных файловых операций. Алгоритм реализует паттерн «один загрузчик — множество ожидающих»:

- а) Под проверяет наличие финального маркер-файла `.ready` в директории модели. Если маркер присутствует, модель готова к использованию; загрузка не требуется, выполнение переходит к запуску runtime-контейнера.
- б) Если маркер отсутствует, под открывает специальный файл блокировки `.lock` в директории модели и выполняет попытку получения эксклюзивной блокировки (`LOCK_EX | LOCK_NB`).
- в) Под, успешно получивший блокировку, становится лидером загрузки. Перед началом загрузки лидер повторно проверяет наличие маркера `.ready` — другой лидер мог успеть завершить загрузку в промежутке между проверкой и получением блокировки. При обнаружении маркера лидер освобождает блокировку и переходит к запуску runtime-контейнера.
- г) Лидер начинает загрузку весов модели во временную директорию `<model>_tmp`, физически расположенную в том же NFS-разделе. Запись ведётся во временную директорию, что гарантирует отсутствие частично записанных данных по целевому пути.
- д) После завершения загрузки всех файлов лидер выполняет верификацию целостности: сравнивает суммарный объём файлов и, при наличии манифеста, проверяет контрольные суммы.
- е) Лидер выполняет атомарное переименование временной директории: `<model>_tmp → <model>`. В POSIX-совместимых файловых системах операция `rename(2)` является атомарной в пределах одной файловой системы: наблюдатели видят либо отсутствие директории, либо полностью готовую директорию, но никогда не видят промежуточного состояния.
- ж) Лидер создаёт маркер-файл `.ready` в директории модели и освобождает файловую блокировку.

Поды, не получившие эксклюзивную блокировку на шаге 2, устанавливают разделяемую блокировку (LOCK_SH) на тот же файл .lock. Вызов flock(LOCK_SH) является блокирующим и возвращает управление только после того, как лидер освободит эксклюзивную блокировку. После возврата из блокирующего вызова под повторно проверяет маркер .ready. Если маркер присутствует, pod переходит к запуску runtime-контейнера. Если маркер отсутствует (например, лидер завершился аварийно до создания маркера), pod повторяет попытку получить эксклюзивную блокировку и при успехе становится новым лидером.

Описанный алгоритм в псевдокоде:

Листинг 3: Псевдокод координированной загрузки модели

```
1 function EnsureModelReady(model_dir, lock_path, ready_marker):
2     if Exists(ready_marker):
3         return OK
4
5     lock_fd = Open(lock_path, CREATE | RDWR)
6
7     if TryLock(lock_fd, LOCK_EX | LOCK_NB) == SUCCESS:
8         # Повторная проверка после получения блокировки
9         if Exists(ready_marker):
10             Unlock(lock_fd)
11             return OK
12
13     tmp_dir = model_dir + "_tmp"
14     err = DownloadModel(source_url, tmp_dir)
15     if err != nil:
16         Unlock(lock_fd)
17         RemoveAll(tmp_dir)
18         return ERROR
19
20     Rename(tmp_dir, model_dir)    # атомарно
21     CreateFile(ready_marker)
22     Unlock(lock_fd)
23     return OK
24 else:
25     # Ожидаем завершения лидера
26     Lock(lock_fd, LOCK_SH)        # блокирующий вызов
27     Unlock(lock_fd)
28     # Рекурсивная проверка маркера
```

3.4 Файловые блокировки `flock` и их особенности поверх NFS

Advisory locking: разделяемые и эксклюзивные блокировки

Системный вызов `flock(2)` реализует рекомендательные (advisory) блокировки на уровне открытого файлового дескриптора [30]. Рекомендательный характер означает, что ядро операционной системы не препятствует доступу к файлу процессам, которые не запрашивают блокировку. Консистентность обеспечивается только при условии, что все участники взаимодействия явно запрашивают и соблюдают соглашение о блокировках.

Поддерживаются два вида блокировок:

- **Разделяемая (`shared`, `LOCK_SH`)** — несколько процессов могут одновременно удерживать разделяемую блокировку на одном файле. Используется для операций чтения, не порождающих конфликтов при параллельном доступе.
- **Эксклюзивная (`exclusive`, `LOCK_EX`)** — только один процесс может удерживать эксклюзивную блокировку. Пока она активна, ни один другой процесс не может получить ни разделяемую, ни эксклюзивную блокировку на тот же файл.

Блокировки `flock` привязаны к описанию открытого файла (open file description), а не к иноду. Это означает, что дублирование файлового дескриптора через `fork(2)` или `dup(2)` приводит к тому, что оба дескриптора ссылаются на одно описание и, следовательно, на одну и ту же блокировку. Блокировка автоматически снимается при закрытии последнего файлового дескриптора, ссылающегося на данное описание открытого файла, или при завершении процесса. Это свойство является встроенной защитой от «зависших» блокировок: аварийное завершение процесса-лидера автоматически освобождает блокировку.

NFSv3: блокировки через Network Lock Manager

Поведение `flock` поверх NFS существенно зависит от версии протокола. В NFSv3 блокировки файлов не являются частью основного

протокола. Они реализуются через вспомогательный сервис Network Lock Manager (NLM), который взаимодействует с демонами `lockd` и `statd` на стороне клиента и сервера.

Данная архитектура имеет ряд ограничений. Демоны `lockd` и `statd` являются дополнительными точками отказа: при их недоступности или некорректной конфигурации операции блокировки возвращают ошибку `ENOLCK`. При сетевом разделе между клиентом и NFS-сервером блокировка может зависнуть. При перезагрузке NFS-сервера состояние блокировок восстанавливается не всегда корректно, что может привести к ситуации, когда двое клиентов считают себя держателями эксклюзивной блокировки. В ранних версиях ядра Linux (до 2.6.11) `flock` поверх NFS ограничивался локальной машиной и не распространял блокировку на другие клиенты.

NFSv4: встроенные блокировки и lease-механизм

В NFSv4 файловые блокировки интегрированы непосредственно в основной протокол, что устраняет зависимость от внешних демонов NLM. Сервер NFSv4 отслеживает состояние всех активных блокировок клиентов через механизм аренды (`lease`): каждый клиент обязан периодически подтверждать свою активность; при истечении аренды сервер освобождает все блокировки данного клиента. Это предотвращает зависшие блокировки даже при аварийном отключении клиента.

Тем не менее NFSv4 не лишён ограничений. В Linux, начиная с версии 2.6.12, клиент NFSv4 эмулирует `flock` через байт-диапазонные блокировки `fcntl(F_SETLK)`, что означает взаимодействие между двумя типами блокировок. Для эксклюзивной блокировки через `flock` файл должен быть открыт с флагом записи, даже если запись не предполагается. При сетевом разделе (`network partition`) сервер продолжает удерживать информацию о блокировках до истечения аренды, а не немедленно освобождает их, что создаёт паузу в доступности ресурса.

Практическая модель надёжности: flock + rename + маркер

Анализ ограничений `flock` поверх NFS показывает, что в производственной среде нельзя полагаться исключительно на корректность блокировок при сетевых сбоях. Именно поэтому описанный алгоритм

координированной загрузки использует комбинацию трёх механизмов, образующих эшелонированную защиту:

- а) **Файловая блокировка (`flock`)** — координирует конкурентный доступ в штатном режиме работы, когда сеть стабильна.
- б) **Атомарное переименование (`rename`)** — гарантирует, что читатели никогда не видят частично записанных данных. Операция `rename(2)` атомарна в пределах одной файловой системы согласно POSIX-стандарту.
- в) **Маркер готовности (`.ready`)** — является финальным критерием готовности модели. Даже если блокировка была выдана некорректно двум клиентам одновременно, только тот под завершит загрузку, который успеет выполнить `rename` и создать маркер первым. Второй под, завершив загрузку во временную директорию, обнаружит, что целевая директория уже существует, и примет её как готовую.

Такая комбинация значительно повышает устойчивость алгоритма к нештатным ситуациям, не требуя строгих гарантий от файловой системы.

3.5 Kubernetes Lease и Leader Election

Ресурс `coordination.k8s.io/v1/Lease`

Файловые блокировки поверх NFS предоставляют достаточную надёжность в большинстве сценариев, однако остаются уязвимыми к ситуациям, связанным с некорректной конфигурацией NFS-клиента или нестандартным поведением NFS-сервера. Для случаев, когда требуется более высокий уровень гарантий, Kubernetes предоставляет встроенный механизм распределённой координации через ресурс `coordination.k8s.io/v1/Lease` [31].

Ресурс `Lease` представляет собой объект Kubernetes API, хранимый в `etcd` и обладающий строгими гарантиями согласованности за счёт оптимистичной блокировки через поле `resourceVersion`. Объект содержит следующие ключевые поля спецификации:

- `holderIdentity` — строковый идентификатор текущего держателя аренды (как правило, имя пода или уникальный идентификатор процесса). Пустое значение означает, что аренда никем не удерживается.

- `leaseDurationSeconds` — максимальная длительность аренды в секундах без обновления. Если текущий держатель не обновил аренду в течение этого интервала, другие кандидаты вправе захватить её.
- `renewTime` — временная метка последнего обновления аренды текущим держателем. Лидер обязан периодически обновлять это поле, чтобы подтвердить свою активность.
- `acquireTime` — временная метка первоначального захвата аренды текущим держателем.
- `leaderTransitions` — счётчик количества смен лидера, полезный для мониторинга стабильности координации.

Kubernetes API-сервер гарантирует, что при одновременной попытке обновить объект `Lease` несколькими клиентами только один запрос будет успешным: операция обновления проверяет `resourceVersion`, и если объект был изменён другим клиентом с момента последнего чтения, запрос отклоняется с ошибкой конфликта. Это свойство обеспечивает выбор ровно одного лидера даже при одновременном участии произвольного числа кандидатов.

Алгоритм `client-go leadelection`

Стандартная библиотека `k8s.io/client-go/tools/leadelection` реализует алгоритм выбора лидера поверх ресурса `Lease`. Алгоритм работает следующим образом:

- а) При запуске каждый кандидат пытается создать объект `Lease` с собственным `holderIdentity` или обновить существующий объект, если аренда истекла. Операция выполняется через Kubernetes API.
- б) Кандидат, чей запрос на обновление был принят первым (с корректным `resourceVersion`), становится лидером. Остальные кандидаты получают ответ о конфликте версии и переходят в режим ожидания.
- в) Лидер периодически (с интервалом `RetryPeriod`) обновляет поле `renewTime` объекта `Lease`, не давая сроку аренды истечь. Функция `OnStartedLeading(ctx)` вызывается при получении статуса лидера и выполняет целевую операцию — загрузку модели.

- г) Если лидер завершается аварийно или теряет связь с API-сервером, обновление `renewTime` прекращается. По истечении `leaseDurationSeconds` аренда помечается как просроченная.
- д) Один из ожидающих кандидатов обнаруживает просроченную аренду, захватывает `Lease` и становится новым лидером. Функция `OnStoppedLeading` вызывается на бывшем лидере при обнаружении потери статуса.

Структура `LeaderElectionConfig` задаёт ключевые параметры: `LeaseDuration` (типовое значение — 15 секунд), `RenewDeadline` (типовое значение — 10 секунд), `RetryPeriod` (типовое значение — 2 секунды), а также набор `callback`-функций (`OnStartedLeading`, `OnStoppedLeading`, `OnNewLeader`).

Координация per-model через пространство имён `Lease`

В контексте загрузки моделей ресурс `Lease` именуется по схеме `model-<name>-<revision>` в пространстве имён соответствующего сервиса инференса. Это позволяет независимо координировать загрузку разных моделей: одновременно могут присутствовать несколько объектов `Lease`, каждый из которых управляет загрузкой конкретной версии конкретной модели.

Лидер, захвативший `Lease` для данной пары (модель, ревизия), выполняет загрузку в NFS, создаёт маркер `.ready` и освобождает `Lease`. Остальные поды, работающие с той же моделью, отслеживают либо состояние `Lease` через механизм `Watch`, либо появление маркера `.ready` в NFS-директории, либо используют оба сигнала в *conjunction*. Данный подход исключает условие гонки на уровне Kubernetes без каких-либо требований к семантике NFS-блокировок.

Преимущество Kubernetes `Lease` перед `flock` состоит в том, что гарантии согласованности обеспечиваются `etcd` — распределённым хранилищем с алгоритмом `Raft`, а не файловой системой. Таким образом, `Leader Election` через Kubernetes `Lease` является предпочтительным механизмом координации для случаев, когда `init`-контейнер имеет доступ к Kubernetes API. В случаях, когда доступ к API недоступен или нежелателен (например, в минималистичных окружениях), `flock` с атомарным переименованием остаётся резервным вариантом.

3.6 Ограничения NFS-этапа

Централизованный сервер как единая точка отказа

Несмотря на существенное улучшение по сравнению со схемой `emptyDir`, NFS-подход обнаружил ряд системных ограничений, которые были выявлены в процессе промышленной эксплуатации и ставшие основанием для разработки следующего этапа архитектуры.

NFS-сервер как SPOF. Весь ввод-вывод чтения весов моделей проходит через один NFS-сервер. При его недоступности — перезагрузке, сетевой проблеме, исчерпании дискового пространства или переполнении очереди запросов — вся система инференса лишается доступа к моделям. Kubernetes не содержит встроенных механизмов высокой доступности для внешнего NFS-сервера: сбой сервера воспринимается как продолжительный таймаут сетевой операции, что приводит к зависанию подов на этапе монтирования или чтения.

Bottleneck пропускной способности. При одновременном масштабировании большого числа реплик все они читают файлы модели через сетевую карту NFS-сервера. Пропускная способность его сетевого интерфейса физически ограничена и не масштабируется горизонтально. При *burst*-масштабировании с 0 до N реплик суммарный входящий трафик на NFS-сервер достигает $N \times$ скорость чтения, что при типичных размерах моделей (7–70 ГБ) быстро приводит к насыщению канала.

Отсутствие локальности данных. Даже если узел уже обслуживал данную модель ранее, при создании нового пода `runtime`-контейнер читает данные из NFS по сети заново. Локальный диск узла не используется для кэширования: информация, однажды прочитанная с NFS, не сохраняется на узле и при следующем запросе снова загружается по сети. Это приводит к тому, что задержка `cold start` определяется не скоростью локального чтения (которая может достигать 3–5 ГБ/с для NVMe), а пропускной способностью сети между нодой и NFS-сервером.

Сложность построения отказоустойчивого NFS. Создание высокодоступного NFS-сервера требует значительных дополнительных усилий: кластеризации с использованием Pacemaker/Corosync, синхронной репликации данных через DRBD или аналогичные средства, настройки

shared-storage для кластерного NFS. Такое решение существенно увеличивает операционную сложность и стоимость инфраструктуры, при этом не устраняя принципиальных проблем с масштабируемостью полосы пропускания.

Нагрузка на сеть при burst-масштабировании. В отличие от схемы `emptyDir`, где нагрузка распределялась между нодами (каждый узел загружал из внешнего источника независимо), в NFS-схеме весь трафик концентрируется на одном сервере. При резком росте числа реплик весь кластер конкурирует за пропускную способность одного сетевого пути.

CAP-теорема и выбор NFS

CAP-теорема [32] утверждает, что распределённая система не может одновременно обеспечивать согласованность (Consistency), доступность (Availability) и устойчивость к разделению сети (Partition tolerance). При разрыве сети (Partition) между нодами Kubernetes и NFS-сервером система вынуждена выбирать между двумя оставшимися свойствами.

Классический NFS с режимом монтирования `hard` выбирает согласованность, жертвуя доступностью: при недоступности сервера все операции ввода-вывода блокируются и ожидают восстановления соединения. Runtime-контейнер, ожидающий чтения весов из NFS, зависает до тех пор, пока сетевой сбой не будет устранён. Режим монтирования `soft` позволяет операциям завершаться с ошибкой по таймауту, однако приводит к потенциальной несогласованности данных при восстановлении.

В итоге NFS-этап предлагает приемлемые характеристики для небольших кластеров с умеренной нагрузкой, но системно неприменим в условиях масштабирования, требующего высокой параллельности и устойчивости к сбоям сети.

3.7 Выводы по разделу

NFS-этап значительно сократил количество обращений к внешнему репозиторию: вместо N независимых загрузок на N реплик однократная загрузка в общее хранилище обеспечивает повторное использование данных всеми подами. Алгоритм координации через файловые блокировки `flock` и маркер готовности обеспечивает консистентность при параллельном старте. Kubernetes Lease API предоставляет более надёжную альтернативу для

координации в случаях, когда гарантии NFS-блокировок недостаточны.

Вместе с тем NFS как централизованное сетевое хранилище переносит проблему с внешнего репозитория на один внутренний сервер, создавая единую точку отказа и ограниченный по пропускной способности ресурс. При масштабировании до десятков параллельных реплик, каждая из которых читает модель размером 7–70 ГБ, NFS-сервер становится узким местом архитектуры. Отсутствие локального кэширования на дисках нод означает, что одни и те же данные многократно передаются по сети при каждом событии масштабирования.

Для устранения этих ограничений необходим переход к архитектуре, в которой данные хранятся на локальных дисках worker-нод и доставляются напрямую между агентами, минуя централизованный сервер. Такая архитектура, реализованная через распределённый кэш на уровне нод с P2P-взаимодействием и FUSE-клиентом, обеспечивает локальность данных, горизонтальную масштабируемость пропускной способности и устойчивость к отказу отдельных компонентов. Именно она составляет содержание следующего раздела.

4 РАЗРАБОТКА P2P/FUSE-СИСТЕМЫ КЭШИРОВАНИЯ ML-MODEЛЕЙ

Данный раздел описывает основную разработку работы — специализированную систему распределённого кэширования ML-моделей, устраняющую ограничения NFS-этапа. Система построена на трёх ключевых компонентах: Redis-реестре метаданных (Control Plane), агенте storage-agent на каждой worker-ноде (Data Plane) и FUSE-клиенте storage-mounter, предоставляющем ML-runtime стандартный файловый интерфейс. Вместе они реализуют трёхуровневую иерархию доступа к данным: локальный диск ноды, P2P-сеть кластера и внешний репозиторий как резервный источник.

4.1 Общая идея и требования к архитектуре

Центральная идея архитектуры состоит в том, что локальные диски worker-нод образуют распределённый кэш, доступный всем подам в кластере. Данные модели хранятся не в одном месте, а распределены между нодами в виде чанков — блоков фиксированного размера. При запуске нового пода ML-runtime обращается к ближайшей копии данных, а не к централизованному NFS или внешнему репозиторию. Этот подход переносит хранилище данных из единого централизованного узла в локальность вычислений, что соответствует принципу data locality, давно утвердившемуся в распределённых системах обработки данных.

Переход от NFS-этапа к P2P/FUSE-архитектуре мотивирован фундаментальным ограничением сетевых файловых систем: единый NFS-сервер становится узким местом при одновременном запуске нескольких подов с тяжёлыми ML-моделями. Если 10 подов одновременно читают модель весом 70 ГБ с одного NFS-сервера, суммарный поток данных составляет сотни гигабайт, что превышает пропускную способность большинства сетевых интерфейсов. P2P-архитектура устраняет это ограничение: каждый под обращается к локальному диску своей ноды или к нескольким соседним нодам, распределяя нагрузку на чтение горизонтально.

Требования, которым должна удовлетворять архитектура, сформулированы исходя из ограничений предшествующих подходов:

- **Минимальная задержка первого байта:** ML-runtime должен

получить первые данные модели в течение миллисекунд, не дожидаясь полной загрузки весов. Это обеспечивается механизмом *lazy loading* через FUSE.

- **Отсутствие единой точки отказа:** падение одной ноды не должно делать модель недоступной. Репликация чанков на несколько нод и *fallback* на внешний репозиторий обеспечивают это свойство.
- **Прозрачность для ML-runtime:** фреймворки vLLM и TGI не должны требовать модификации кода для работы с системой. FUSE предоставляет стандартный POSIX-интерфейс.
- **Масштабируемость:** добавление новых нод должно автоматически увеличивать совокупный кэш без перенастройки.
- **Устойчивость к stale metadata:** устаревшие записи об ушедших нодах должны автоматически удаляться через TTL механизм Redis.
- **Совместимость с Kubernetes:** компоненты должны разворачиваться стандартными Kubernetes-примитивами (DaemonSet, ConfigMap, Secret) без изменения прав хостовой системы, за исключением доступа к диску.

Разработанная архитектура логически делится на три уровня.

Уровень 1. Control Plane (Реестр метаданных). Роль центрального источника информации выполняет Redis-кластер. В нём хранятся метаданные о каждом чанке каждой модели: на каких нодах он расположен, каков его размер и хеш. Кроме того, каждый активный *storage-agent* периодически обновляет запись о себе (*heartbeat*) с TTL. Redis выступает «телефонной книгой» кластера: любой компонент может узнать, у каких агентов есть нужный чанк, за одну операцию чтения. Control Plane намеренно отделён от Data Plane: метаданные не смешиваются с данными, что упрощает масштабирование и отказоустойчивость каждого уровня независимо.

Уровень 2. Data Plane — локальный (Инференс и виртуальная файловая система). На каждой *compute-ноде* работает контейнер с ML-движком и компонент *storage-mounter*. FUSE-клиент монтирует виртуальную файловую систему в локальный путь пода. Для ML-движка создаётся иллюзия, что файлы модели уже целиком лежат на диске. При чтении определённого диапазона байтов *storage-mounter* перехватывает системный вызов и по Unix Domain Socket запрашивает данные у локального *storage-agent*. UDS выбран намеренно: коммуникация остаётся в

пределах одного хоста и не нагружает сеть датацентра.

Уровень 3. Data Plane — горизонтальный (P2P-сеть). При промахе локального кэша `storage-agent` обращается к Redis для поиска узла, имеющего нужный чанк. Данные передаются напрямую по TCP между агентами на разных нодах. Если чанк отсутствует во всём кластере — выполняется fallback-загрузка из внешнего репозитория (HuggingFace, Ollama, ModelScope). Горизонтальный Data Plane реализует свойство self-healing кэша: каждая загрузка из внешнего источника наполняет локальный кэш, уменьшая вероятность повторного обращения к внешнему репозиторию.

4.2 Модель данных: репозиторий, модель, ревизия, файл, чанк

Для корректного кэширования и адресации данных принята иерархическая модель, отражающая структуру реестров ML-моделей. Иерархия адресации включает следующие уровни:

- **registry** — источник модели: `huggingface`, `ollama`, `modelscope`;
- **repository** — пространство имён владельца (например, `meta-llama`);
- **model** — имя модели (например, `Llama-3-70B-Instruct`);
- **revision** — версия модели (`commit hash` или `ter`); обеспечивает иммутабельность кэша;
- **filepath** — относительный путь к файлу внутри репозитория (например, `model-00001-of-00004.safetensors`);
- **chunk_id** — порядковый номер чанка в файле (начиная с 0);
- **chunk_size** — фиксированный размер чанка (настраивается, типично 8–64 МБ).

Иммутабельность через `revision` принципиально важна для корректности кэша. Файлы конкретной ревизии модели никогда не изменяются: если `revision` зафиксирован как конкретный `commit hash`, то содержимое файлов при данном `hash` всегда одинаково. Поэтому кэшированный чанк всегда корректен, пока `revision` в ключе совпадает с запрошенной версией. Это устраняет необходимость в механизмах инвалидации кэша при обновлении модели: новая версия получает новый `revision`, и её чанки хранятся независимо от чанков предыдущей версии. Старые чанки вытесняются по LRU-политике по мере заполнения диска.

Физический путь к чанку на диске агента строится следующим образом:

```
<cache_dir>/
```

```
<registry>/<repo>/<model>/<revision>/  
  <hash(filepath)[0:2]>/  
    <hash(filepath)[2:4]>/  
      <hash(filepath)>/  
        chunk_<chunk_id>
```

Хеширование пути к файлу решает две задачи. Первая — устранение проблемы специальных символов и длинных имён: имена файлов в HuggingFace-репозиториях могут содержать слеш, пробелы и длинные пути, несовместимые с прямым использованием в качестве имени файла на диске. Хеш SHA-256 от filepath даёт детерминированное, фиксированной длины имя директории. Вторая задача — равномерное распределение файлов: файловые системы Linux имеют ограничения на число записей в одной директории (ext4 — до нескольких десятков тысяч записей без dir_index, что вызывает деградацию производительности); двухуровневое шардирование по первым четырём символам хеша обеспечивает $256 \times 256 = 65536$ возможных поддиректорий, практически исключая перегрузку отдельных директорий.

Ключ в Redis для записи о чанке строится аналогично иерархии на диске:

```
<registry>:<repo>:<model>:<revision>:<hash(filepath)>:<  
  chunk_id>
```

Такая схема позволяет находить все чанки конкретного файла по префиксу ключа через SCAN, а также атомарно получать список нод, хранящих конкретный чанк, одной командой SMEMBERS. Единообразие схемы адресации между диском и Redis упрощает отладку: по ключу в Redis можно немедленно определить физический путь на диске агента.

Размер чанка влияет на компромисс между накладными расходами и гранулярностью. Мелкие чанки (4–8 МБ) допускают более точное управление тем, какие части модели кэшируются, но увеличивают число метаданных в Redis и число операций FUSE. Крупные чанки (64–128 МБ) снижают накладные расходы, но могут приводить к загрузке данных, которые ML-runtime не запросит. Диапазон 16–32 МБ является практически обоснованным для последовательного чтения больших .safetensors-файлов в ML-инференсе.

4.3 Redis как реестр метаданных чанков

Обоснование выбора Redis

Выбор Redis в роли Control Plane обусловлен рядом характеристик, критичных для задачи реестра метаданных в динамической P2P-среде.

Суб-миллисекундная задержка. Redis хранит данные в оперативной памяти и обеспечивает время отклика на операции чтения и записи, измеряемое микросекундами [33]. При обработке запроса чанка `storage-agent` выполняет один `SMEMBERS`-запрос к Redis перед обращением к соседнему узлу: накладные расходы на этот `lookup` должны быть пренебрежимо малы по сравнению со временем сетевой передачи чанка (десятки–сотни миллисекунд). Суб-миллисекундная задержка Redis делает его не узким местом системы.

Атомарность операций. Команды `SADD`, `HSET`, `EXPIRE` выполняются атомарно. Это позволяет агенту регистрировать чанк без состояний гонки: добавить свой идентификатор в множество пиров (`SADD chunk:....:peers <node_id>`) и установить метаданные (`HSET chunk:....:meta size ... checksum ...`) атомарно. Другой агент, запрашивающий `SMEMBERS chunk:....:peers`, получит либо запись целиком, либо вообще не получит идентификатор данного узла — промежуточного состояния не существует.

Встроенный TTL. Каждый ключ в Redis может иметь ограниченное время жизни. Если агент прекратил публиковать `heartbeat` (нода упала или перезагрузилась), его записи исчезнут автоматически через TTL. Это устраняет необходимость в явном механизме `garbage collection`: реестр самоочищается без дополнительного координатора. Redis использует комбинацию ленивого удаления (при обращении к истёкшему ключу) и периодической активной очистки, обеспечивая эффективное управление памятью при наличии TTL.

Горизонтальное масштабирование. Redis Cluster шардирует ключи по 16384 хеш-слотам, распределяя нагрузку между мастер-узлами. При отказе мастера кластер автоматически повышает реплику [33]. Redis Sentinel решает аналогичную задачу для меньших кластеров: мониторит мастер, выполняет автоматическое переключение на реплику при его недоступности [34]. Оба

решения устраняют Redis как единую точку отказа, что было ключевым недостатком NFS-этапа.

Сравнение с альтернативами. etcd обеспечивает строгую линейную консистентность через алгоритм Raft, но вносит задержку в единицы миллисекунд и оптимизирован для небольшого объёма редко меняющихся данных конфигурации — не для высокочастотного реестра тысяч чанков. ZooKeeper не имеет встроенного TTL и требует сложного клиентского кода для имитации его функциональности; кроме того, ZooKeeper написан на Java и сложен в операционном обслуживании. Consul избыточен: большинство его возможностей (service mesh, ACL, health checks) не используются при решении задачи реестра чанков. Redis обеспечивает точно необходимый набор: быстрое чтение/запись эфемерных метаданных, автоматический TTL, богатые структуры данных (Sets, Hashes), горизонтальное масштабирование.

Схема ключей

В реестре применяется следующая трёхуровневая схема ключей:

- `node:<node_id>` — heartbeat агента. Значение (JSON или строка) содержит IP-адрес, TCP-порт, load score, метку времени последнего обновления. TTL = 30–60 с. Если агент не обновляет heartbeat, запись автоматически исчезает, и следующий запрос к этому агенту не выполняется.
- `chunk:<logical_id>:peers` — Set идентификаторов нод, хранящих данный чанк. Операция SADD `<node_id>` регистрирует ноду; SMEMBERS возвращает всех известных пиров за $O(1)$ (одна хеш-таблица в памяти Redis). Сложность SMEMBERS для Set из k пиров — $O(k)$.
- Hash с метаданными чанка строится по следующей схеме:

```
model:<registry>:<repo>:<model>:<revision>:
  file:<hash>:chunk:<id>:meta
```

В Hash хранятся размер в байтах (`size`) и контрольная сумма SHA-256 (`checksum`); ключ используется для верификации целостности после загрузки.

Разделение информации о пирах и метаданных чанка на два ключа (`:peers` и `:meta`) позволяет обновлять их независимо. Метаданные чанка (размер, хеш) не изменяются после первой записи — ключ `:meta` фактически

write-once. Множество пиров (:peers) динамически растёт по мере того, как новые ноды кэшируют чанк, и может уменьшаться при явном SREM или истечении TTL.

После успешного сохранения чанка на диске агент выполняет следующую атомарную последовательность: SADD chunk:...:peers <node_id> и HSET chunk:...:meta size <n> checksum <sha256>. Это обеспечивает согласованность реестра с фактическим состоянием дисков.

Heartbeat и управление жизненным циклом

Каждый storage-agent публикует heartbeat каждые 10–30 с командой:

```
SET node:<node_id> <metadata_json> EX <ttl>
```

Команда SET ... EX атомарно записывает значение и устанавливает TTL. Это исключает ситуацию, когда значение записано, но TTL ещё не установлен — состояние, которое возникло бы при раздельном вызове SET и EXPIRE.

TTL выбирается в диапазоне 2–3 интервалов heartbeat: при TTL = 60 с и интервале heartbeat = 20 с нода выдерживает 3 пропущенных heartbeat прежде чем её запись устареет. Это обеспечивает устойчивость к кратковременным сбоям сети (задержке heartbeat) без риска оставить в реестре записи реально отказавших нод.

Любой агент, запрашивающий список пиров для чанка, проверяет свежесть каждого кандидата: EXISTS node:<peer_id>. Если heartbeat истёк, агент пропускает данный пир и переходит к следующему. Это двухуровневая проверка: TTL heartbeat — первый уровень защиты, явная проверка EXISTS — второй.

4.4 Обнаружение узлов: Gossip, mDNS и Redis heartbeat

Для построения реестра активных агентов рассматривались три подхода.

Gossip Protocol

Gossip (эпидемический протокол) — децентрализованный механизм, при котором каждый узел периодически обменивается состоянием с k

случайно выбранными соседями [35]. Выбор соседей случаен и независим в каждом раунде, что обеспечивает экспоненциальное распространение информации: после r раундов информация достигает примерно $(k+1)^r$ узлов (при отсутствии пересечений). Для кластера из N нод информация распространяется за:

$$T_{\text{gossip}} = O(\log N). \quad (5)$$

Для кластера из 1000 нод это порядка 10 раундов; для 25 000 нод — около 15 раундов. Каждый раунд занимает время, равное интервалу gossip (обычно 1–5 с), что означает задержку сходимости от 10 до 75 с для крупных кластеров. Именно этот временной разрыв делает Gossip неприемлемым для задачи реестра чанков.

Преимущества Gossip: полная децентрализация без центрального координатора, высокая отказоустойчивость — протокол продолжает работать при отказе произвольного числа узлов, масштабируемость до сотен тысяч нод. Gossip применяется в Redis Cluster для обмена информацией о конфигурации слотов и состоянии узлов, а также в Apache Cassandra и HashiCorp Consul для поддержания актуальной топологии. Для этих применений eventual consistency приемлема, поскольку топология меняется редко.

Недостатки для задачи реестра чанков: задержка сходимости $O(\log N)$ раундов неприемлема при cold start, где каждая миллисекунда критична. Gossip создаёт постоянный фоновый трафик (каждый узел периодически иницирует обмен с несколькими соседями), что нагружает сеть. Отладка eventual-consistent системы существенно сложнее: нет гарантии, что в момент запроса реестр отражает актуальное состояние. Наконец, Gossip не даёт детерминированного ответа на вопрос «где сейчас находится чанк X» — только вероятностный.

mDNS/UDP Broadcast

Multicast DNS (RFC 6762) позволяет устройствам в локальной сети анонсировать себя через UDP-мультикаст на адрес 224.0.0.251, порт 5353 [36]. Каждое устройство периодически отправляет mDNS Announcement, сообщая своё имя хоста и IP-адрес. Другие устройства могут найти сервис через mDNS Query.

В качестве механизма zero-configuration networking mDNS прост в реализации и не требует дополнительной инфраструктуры — достаточно стандартной поддержки в ОС. Именно это делает mDNS популярным в домашних сетях (Apple Bonjour, DNS-SD).

Однако mDNS имеет серьёзные ограничения в среде Kubernetes [36]:

- **Overlay-сети блокируют мультикаст:** большинство CNI-плагинов (Calico, Flannel, Cilium) используют VXLAN или IPIP, которые инкапсулируют L2-трафик в L3-пакеты и не распространяют мультикаст-фреймы между хостами.
- **Отсутствие IGMP/PIM в облаке:** облачные провайдеры (AWS, GCP, Azure) не поддерживают multicast routing на уровне underlay-сети.
- **Нарушение сетевой изоляции:** обходной путь через `hostNetwork: true` даёт поду доступ к мультикасту хостовой сети, но нарушает принципы сетевой изоляции Kubernetes и создаёт риски безопасности.
- **Ограниченная масштабируемость:** мультикаст масштабируется только в пределах одного broadcast-домена (VLAN), что несовместимо с multi-zone кластерами, охватывающими несколько зон доступности.

Таким образом, mDNS неприменим для обнаружения узлов в типичном production Kubernetes-кластере.

Redis heartbeat: выбранный подход

Каждый `storage-agent` периодически обновляет запись о себе в Redis с TTL. Поиск активных агентов сводится к одному SCAN по префиксу `node:*` или `SMEMBERS` для конкретного чанка. Это обеспечивает время поиска $O(1)$, что принципиально отличает Redis heartbeat от Gossip ($O(\log N)$ раундов).

Таблица 4 обобщает ключевые различия трёх подходов. Из анализа следует, что для кластеров Kubernetes умеренного масштаба (до нескольких тысяч нод) Redis heartbeat обеспечивает оптимальный баланс: минимальная задержка поиска, детерминированный ответ, прозрачная интеграция с Kubernetes-инфраструктурой.

Единственный риск — зависимость от доступности Redis — устраняется развёртыванием Redis Sentinel (для кластеров малого и среднего масштаба) или Redis Cluster с несколькими мастерами и репликами (для больших кластеров). При временной недоступности Redis `storage-agent` переключается на локальный кэш и fallback, сохраняя работоспособность.

Таблица 4 – Сравнение алгоритмов обнаружения узлов

Критерий	Gossip	mDNS/ Broadcast	Redis heartbeat	
Скорость lookup	$O(\log N)$ раундов	Быстро (локальная сеть)	$O(1)$	
Консистентность	eventual	Нет	TTL-based	
Поддержка в K8s	Да	Плохая	Да	
SPOF	Нет	Нет	Redis (без HA)	
Сложность реализации	Средняя	Низкая	Низкая	
Масштабируемость	Высокая	Ограниченная	Высокая (Cluster)	
Гарантия актуальности	Нет (eventual)	Только локальная сеть	TTL- ограниченная	

4.5 Компонент storage-agent: DaemonSet-агент на каждой ноде

storage-agent — агент, развёртываемый как DaemonSet на каждой worker-ноде кластера. Kubernetes DaemonSet гарантирует, что на каждой подходящей ноде запущен ровно один экземпляр, который автоматически создаётся при добавлении новой ноды и удаляется при её выводе из эксплуатации. Агент монтирует локальный диск ноды (через hostPath volume) и использует его как кэш-хранилище чанков.

Использование DaemonSet вместо Deployment критически важно: именно DaemonSet обеспечивает ковенант «один агент на ноду», без которого невозможно гарантировать, что локальный кэш ноды управляется ровно одним процессом. Конкурентный доступ нескольких агентов к одному кэш-директории потребовал бы механизма блокировок, что усложнило бы архитектуру.

Агент является основным компонентом Data Plane и выполняет следующие функции:

- управление локальным диском и chunk-кэшем ноды (запись, чтение, вытеснение по LRU);
- обслуживание запросов от локального storage-mounter через Unix

Domain Socket (в целевой архитектуре);

- обслуживание TCP-запросов от агентов на соседних нодах (P2P-поставщик чанков);
- периодическая публикация heartbeat и метаданных чанков в Redis;
- fallback-загрузка чанков из внешнего репозитория при их отсутствии в кластере.

HTTP API и текущая реализация

В текущем прототипе реализован HTTP-API с двумя основными эндпоинтами:

- получение дерева файлов модели (имена файлов, размеры, хеши):

```
GET /api/v1/models/{registry}/{repo}/{model}/  
    {revision}/tree
```

- чтение диапазона байтов файла модели:

```
GET /api/v1/models/{registry}/{repo}/{model}/  
    {revision}/raw/{filepath}
```

Диапазон байтов в запросе чтения задаётся HTTP-заголовком `Range: bytes=X-Y`.

Выбор HTTP как протокола в текущем прототипе обусловлен простотой реализации и отладки. В целевой архитектуре для локальной связи `storage-mounter` → `storage-agent` планируется переход на бинарный протокол поверх UDS для снижения накладных расходов.

Компонент `model-gateway` реализует приоритетный порядок источников при обработке запроса чанка:

- а) проверяется наличие чанка в локальном хранилище (`localstorage`) через `os.Stat` по физическому пути;
- б) при промахе инициируется загрузка из HuggingFace через HTTP Range Request;
- в) загруженный чанк записывается на локальный диск атомарно: сначала во временный файл в той же файловой системе, затем переименовывается через `os.Rename`.

Атомарная запись через `os.Rename` критически важна: системный вызов `rename(2)` на Linux атомарен при условии, что исходный и целевой пути находятся в одной файловой системе. Это гарантирует, что конкурентный читатель никогда не увидит частично записанный чанк: файл

либо полностью существует, либо отсутствует. Этот инвариант устраняет необходимость в явных блокировках при параллельных запросах к одному чанку.

Компонент `localstorage` организует файлы на диске по иерархии, описанной в разделе 4.2. Доступ к метаданным файловой системы (размер чанка, наличие файла) осуществляется через `os.Stat`, что исключает необходимость отдельной локальной базы данных: файловая система сама является индексом локального кэша.

Поддержка `singleflight` для предотвращения `thundering herd`

При одновременном поступлении нескольких запросов одного и того же чанка (например, когда несколько горутин в `storage-mounter` запрашивают один чанк параллельно) без специальных мер каждый запрос инициирует отдельную загрузку из внешнего источника. Это явление называется `thundering herd`. Для его предотвращения планируется использование механизма `golang.org/x/sync/singleflight`: если загрузка чанка уже выполняется, повторные запросы ожидают её завершения и получают тот же результат. Это сокращает нагрузку на внешний репозиторий и ускоряет ответ повторным запросам.

Целевое P2P-расширение

В целевой архитектуре `storage-agent` дополняется логикой P2P-обмена. При промахе локального кэша агент выполняет следующую последовательность:

- а) запрашивает Redis: `SMEMBERS chunk:<id>:peers` для получения списка нод с нужным чанком;
- б) фильтрует список: проверяет `EXISTS node:<peer_id>` для каждого кандидата;
- в) ранжирует кандидатов по `load score` и задержке;
- г) скачивает чанк по TCP от выбранного пира;
- д) сохраняет на локальный диск атомарно через `os.Rename`;
- е) регистрирует себя в Redis: `SADD chunk:<id>:peers <local_node_id>`.

Этот процесс замыкает P2P-цикл: каждый новый потребитель чанка

становится потенциальным поставщиком для следующего. После нескольких таких циклов чанки популярных моделей распространяются по кластеру органически, без центрального координатора.

Многоуровневый кэш storage-agent

Эффективность `storage-agent` как прокси-шлюза между `storage-mounter` и внешними реестрами определяется организацией кэша. В прототипе реализована трёхуровневая иерархия, каждый уровень которой обслуживает свой класс запросов.

L0 — горячий уровень в оперативной памяти. Компонент `inMemoryChunkCache` реализует SLRU-кэш (Segmented Least Recently Used) с ёмкостью, задаваемой в байтах. Внутри кэша поддерживается двусвязный список активных чанков и два хеш-словаря: первый сопоставляет ключ (идентификатор модели и номер чанка) с узлом списка, второй — с самими данными. При обращении к чанку его узел перемещается в начало списка. При переполнении ёмкости вытеснение выполняется с хвоста списка, пока не освободится достаточно места. Время операций `Get` и `Set` составляет $O(1)$. Уровень L0 обслуживает повторные обращения к одним и тем же чанкам без дискового ввода-вывода; при перезапуске агента его содержимое теряется, однако это допустимо, поскольку данные восстановимы с диска или из внешнего источника.

L1 — персистентный кэш на локальном диске. Каждый чанк хранится как отдельный файл в иерархии директорий, описанной в разделе 4.2. Запись на диск выполняется по схеме `write-behind`: метод `Write()` помещает чанк в буферизованный канал и немедленно возвращает управление, не дожидаясь физической записи. Отдельная горутина-воркер читает из канала и записывает файл атомарно — сначала во временный файл в той же файловой системе, затем вызывает `os.Rename()`. Атомарность `rename(2)` гарантирует, что конкурентный читатель никогда не увидит частично записанного чанка. Разделение пути записи и пути чтения устраняет задержку дисковой операции из критического пути ответа клиенту.

Выбор файлового кэша. Альтернативы на основе встроенных хранилищ — `BadgerDB`, `BoltDB`, `LevelDB` — не подходят для чанков размером 16–128 МБ. LSM-деревья (`BadgerDB`, `Pebble`) оптимизированы для записи небольших значений: крупные значения уходят в `Value Log`, что порождает

write amplification и фрагментацию. BoltDB хранит все данные в едином B-tree файле с эксклюзивной блокировкой при записи, что создаёт конкуренцию под нагрузкой. Файловый кэш лишён этих ограничений: операционная система обеспечивает параллельный доступ к независимым файлам, а её page cache автоматически удерживает горячие чанки в RAM без дополнительного уровня буферизации.

Расширение: SQLite-индекс для структурированного вытеснения. В текущей реализации удаление устаревших чанков требует обхода файловой системы по времени последнего доступа (`atime`). Запланированное расширение — таблица SQLite в WAL-режиме с записями (`model_ref`, `chunk_id`, `size_bytes`, `last_access_unix`) — позволит выполнять LRU-вытеснение запросом вида `ORDER BY last_access_unix ASC LIMIT N`, не читая файловую систему. Пара SQLite WAL + файловый кэш сохраняет преимущества прямого I/O и при этом добавляет структурированный учёт использования.

Улучшение: ARC вместо LRU для горячего уровня. При смешанной нагрузке — повторные обращения к популярным моделям параллельно с разовыми сканированиями при первой загрузке — чистый LRU вытесняет горячие чанки разовыми промахами. Алгоритм ARC (Adaptive Replacement Cache) поддерживает два рабочих списка (`T1` — недавно добавленные, `T2` — повторно запрошенные) и два ghost-списка ключей (`B1` и `B2`). Попадания в `B1` сдвигают внутреннюю границу p в пользу рецентности, в `B2` — в пользу частотности. Это делает ARC самонастраивающимся без ручного подбора параметров.

4.6 Компонент storage-mounter: FUSE-клиент

`storage-mounter` — FUSE-клиент, предоставляющий ML-runtime стандартный файловый интерфейс для доступа к весам модели. Он монтирует виртуальную файловую систему в путь внутри пода (например, `/mnt/models`).

Механизм FUSE

FUSE (Filesystem in Userspace) позволяет реализовать файловую систему в виде обычного пользовательского процесса без привилегий `root` и

без изменения кода ядра [37]. Архитектура включает три взаимодействующих компонента:

- **Ядерный модуль `fuse.ko`**: перехватывает обращения VFS к FUSE-точке монтирования и передаёт запросы пользовательскому демону через символьное устройство `/dev/fuse`.
- **VFS (Virtual Filesystem Switch)**: единый интерфейс ядра Linux для всех файловых систем; именно он определяет, что файл принадлежит FUSE-ФС, и направляет запрос соответствующему обработчику.
- **Пользовательский демон**: реализует логику файловой системы; в данном случае — `storage-mounter`, написанный на Go с использованием библиотеки `github.com/hanwen/go-fuse/v2` [38].

Жизненный цикл системного вызова `read()` в FUSE выглядит следующим образом:

- а) Приложение ML-runtime (vLLM) вызывает `read(fd, buf, count)`.
- б) Ядро перехватывает вызов через VFS, определяет принадлежность файла к FUSE-ФС.
- в) Ядерный модуль `fuse.ko` упаковывает запрос в пакет протокола FUSE и помещает в очередь.
- г) Пользовательский демон `storage-mounter` читает пакет из `/dev/fuse`.
- д) Демон обрабатывает запрос: вычисляет `chunk_id`, обращается к `storage-agent`.
- е) `storage-agent` возвращает данные чанка.
- ж) Демон записывает ответ обратно в `/dev/fuse`.
- и) Ядро передаёт данные приложению.

Для ML-runtime этот процесс полностью прозрачен: он воспринимает FUSE-ФС как обычную локальную файловую систему. Это ключевое свойство позволяет интегрировать систему без изменения кода vLLM или TGI.

Преимущество FUSE перед альтернативами — CSI volume с полным копированием весов в `emptyDir` — в поддержке `lazy loading`: данные загружаются только при обращении к конкретному диапазону байтов. ML-runtime может начать инициализацию первых слоёв модели ещё до того,

как остальные веса получены с диска или из сети. Это перекрывает фазы вычисления и ввода-вывода, сокращая время cold start.

Накладные расходы FUSE. Каждый системный вызов, направленный FUSE-ФС, требует переключения контекста `kernel` $\leftrightarrow$ `userspace`. Для рабочей нагрузки ML-инференса, при которой читаются большие последовательные блоки (`.safetensors`-файлы по несколько гигабайт), накладные расходы минимизируются за счёт крупных чанков: каждое переключение контекста амортизируется на несколько мегабайт полезных данных. Для мелкогранулярного случайного доступа FUSE может быть неоптимален, однако паттерн чтения ML-весов — преимущественно последовательный.

Ключевые операции

`storage-mounter` реализует следующие FUSE-операции [38]:

- `getattr` — возвращает метаданные файла: размер, права, тип. Позволяет ML-runtime видеть полный размер файла модели без его загрузки. Вызывается при каждом обращении к пути и при выполнении `stat(2)`.
- `readdir` — возвращает список файлов директории модели. Получается из HuggingFace API (`/api/models/<repo>/tree/<revision>`) и кэшируется локально на стороне клиента.
- `lookup` — разрешает имя файла в `inode`. Вызывается при открытии файла по имени; возвращает атрибуты файла или `ENOENT`.
- `open` — открывает файл для чтения. Может проверять права доступа и инициализировать внутренние структуры для отслеживания паттерна чтения.
- `read(offset, size)` — читает диапазон байтов файла. Здесь происходит ключевая трансляция в `chunk`-запросы к `storage-agent`.

Трансляция `read(offset, size)` в `chunk`-запросы

Ключевая операция `read(offset, size)` транслируется в запросы чанков следующим образом. По значениям `offset` и `chunk_size` вычисляется диапазон затронутых чанков:

$$chunk_id_{\text{start}} = \left\lfloor \frac{offset}{chunk_size} \right\rfloor, \quad chunk_id_{\text{end}} = \left\lfloor \frac{offset + size - 1}{chunk_size} \right\rfloor. \quad (6)$$

Для каждого чанка в диапазоне $[chunk_id_{\text{start}}, chunk_id_{\text{end}}]$ отправляется отдельный запрос к `storage-agent`. При $chunk_size = 16$ МБ и запросе на чтение 64 МБ, начиная с произвольного смещения, затронуто не более 5 чанков (4 полных + 1 граничный). Полученные данные объединяются в буфере, из которого вырезается точный запрошенный диапазон. Граничные чанки используются частично: первый — начиная с $offset \% chunk_size$, последний — до $(offset + size - 1) \% chunk_size + 1$.

Текущая реализация и целевое развитие

В текущем прототипе `storage-mounter` реализован с использованием библиотеки `github.com/hanwen/go-fuse/v2` [38]. Поддержаны операции `Lookup`, `Getattr`, `Readdir`. Список файлов модели получается из HuggingFace API. Операция `read` в текущей реализации делегируется непосредственно к API HuggingFace через HTTP Range Request.

В целевой архитектуре операция `read` транслируется в запросы к локальному `storage-agent` через UDS: вместо прямого обращения к внешнему репозиторию `storage-mounter` запрашивает чанк у агента, который обслуживает три сценария — `local cache hit`, `peer hit`, `remote fallback`.

Дополнительно планируется реализация `prefetching`: при обнаружении последовательного паттерна чтения `storage-mounter` асинхронно запрашивает следующие N чанков до их явного запроса ML-runtime. Это позволяет скрыть задержку сетевой или дисковой передачи за временем обработки текущего чанка GPU-ядром.

Кэш и буферизация чтения в `storage-mounter`

`storage-mounter` обрабатывает поток системных вызовов `read()` от ML-runtime и транслирует их в запросы чанков к `storage-agent`. Для минимизации задержки и нагрузки на агента в стороне клиента реализовано несколько механизмов буферизации.

Кольцевой буфер (`streaming ring buffer`). Компонент

`streaming.Cache` хранит массив фиксированной длины `capacity`, в котором чанк с номером k размещается по индексу $k \bmod \text{capacity}$. Запись нового чанка всегда успешна и выполняется за $O(1)$: если в слоте уже находится другой чанк, он вытесняется без дополнительных сравнений. Чтение проверяет соответствие `chunk.Id == chunkId`: при коллизии двух чанков с одинаковым индексом результат возвращается как промах. Такая схема оптимальна для последовательного чтения одного файла: при линейном обходе каждый слот занимает следующий чанком ровно тогда, когда предыдущий уже не нужен.

Предзагрузчик (prefetcher). При каждом вызове `Read(chunkId)` предзагрузчик запускает до `prefetchAhead-1` горутин, каждая из которых загружает следующий чанк, если его нет в кольцевом буфере. Количество одновременно выполняемых предзагрузок ограничивается параметром `prefetchParallelism`, что предотвращает насыщение полосы пропускания UDS-соединения. Для исключения дублирующихся загрузок одного чанка несколькими горутинami применяется механизм `singleflight.Group`: если загрузка данного `chunkId` уже выполняется, повторный запрос блокируется и получает тот же результат без отдельного обращения к агенту. Эффект предзагрузки — перекрытие фаз вычисления GPU и сетевого ввода-вывода: пока GPU обрабатывает текущий слой модели, следующие чанки уже загружаются в буфер.

Пул байтовых буферов. Каждый чанк требует выделения байтового буфера объёмом `chunkSize`. При параллельных запросах нескольких FUSE-горутин без механизма переиспользования каждый вызов `make([]byte, chunkSize)` создаёт новую аллокацию: при `chunkSize = 32` МБ и 64 параллельных горутинax это даёт 2 ГБ аллокаций в секунду, что насыщает сборщик мусора. Компонент `pool.Pool` реализует мультиразмерный пул через `sync.Pool`: для каждого уникального значения `chunkSize` хранится отдельный пул. Метод `Get(size)` возвращает переиспользованный буфер, `Put(buf)` возвращает его в пул после обработки чанка.

Ring buffer vs per-file LRU. Рабочая нагрузка ML-инференса преимущественно последовательна: слои `.safetensors`-файла читаются от начала к концу, поэтому кольцевой буфер покрывает этот сценарий без коллизий. Однако шардированные модели (несколько

.safetensors-файлов, загружаемых одновременно) порождают коллизии: чанки разных файлов с одинаковым номером вытесняют друг друга по модулю ёмкости буфера. В этом сценарии предпочтительна per-file LRU-структура: отдельный LRU-кэш для каждого открытого файла изолирует их чанки. Реализация per-file LRU хранит словарь `filepath → lruCache` с очисткой записи при закрытии файла. Кольцевой буфер остаётся предпочтительным для одиночных больших файлов как более простой и эффективный; переход к per-file LRU оправдан при наличии двух и более одновременно открытых файлов с перекрывающимися диапазонами `chunkId`.

4.7 UDS и TCP: разделение локальной и междоузовой коммуникации

Архитектура применяет два различных транспортных протокола в зависимости от физической топологии взаимодействия. Разделение транспортных протоколов по границе «внутри ноды / между нодами» отражает фундаментальные различия в задержке и модели безопасности.

Unix Domain Socket: внутриузловая связь

Unix Domain Socket (UDS) используется для связи `storage-mounter → local storage-agent` на одной ноде. UDS работает через файловую систему (`/var/run/storage-agent.sock`), минуя IP-стек полностью. Ключевые технические свойства UDS:

- **Отсутствие сетевого стека:** данные не инкапсулируются в IP/TCP-пакеты; нет расчёта контрольных сумм, маршрутизации, обработки заголовков, трёхстороннего рукопожатия.
- **Копирование через память ядра:** передача данных осуществляется прямым копированием между адресными пространствами процессов в ядре. Типичная задержка — 1–5 мкс, пропускная способность — до 10 ГБ/с.
- **Изоляция через права доступа:** права на socket-файл (`chmod/chown`) определяют, какие процессы могут устанавливать соединение. Механизм `SO_PEERCRED` позволяет серверу получить PID, UID и GID клиента непосредственно от ядра без дополнительной

аутентификации.

- **Нет NetworkPolicy**: UDS не пересекает сетевые границы Kubernetes, поэтому политики NetworkPolicy к нему неприменимы.

TCP: междоузловая связь

TCP используется для связи storage-agent → storage-agent между нодами. TCP обеспечивает надёжную упорядоченную доставку данных, управление потоком и контроль перегрузки — свойства, необходимые при передаче чанков объёмом 8–64 МБ по реальной сети. TCP-соединения совместимы со всеми CNI-плагинами и политиками NetworkPolicy.

Контроль перегрузки TCP (алгоритмы CUBIC, BBR) автоматически адаптирует скорость передачи к доступной пропускной способности канала и реагирует на потери пакетов. Это особенно важно при одновременной P2P-передаче нескольких чанков между несколькими парами нод: TCP предотвращает перегрузку коммутаторов датацентра.

Таблица 5 – Сравнение UDS и TCP в контексте системы

Критерий	UDS	TCP
Область применения	Один узел	Разные узлы
IP-стек	Отсутствует	Используется
Задержка	1–5 мкс	0,1–1 мс (RTT в ДЦ)
Накладные расходы	Минимальные	Заголовки, handshake, CRC
Надёжность	Да (ядро ОС)	Да (ACK, retransmit)
Flow control	Нет	Да (TCP window)
Congestion control	Нет	Да (CUBIC, BBR)
Безопасность	FS perms, SO_PEERCREC	TLS/mTLS (целевое)
K8s NetworkPolicy	Не применима	Применима

Таблица 5 демонстрирует, что выбор протокола строго определяется физическим расположением компонентов: UDS — когда оба процесса на одном хосте, TCP — при междоузловом взаимодействии. Комбинация двух протоколов даёт оптимум: внутри ноды минимальная задержка UDS, между нодами надёжность и совместимость TCP.

Оценка пропускной способности через BDP

Произведение полосы пропускания и задержки (BDP, Bandwidth-Delay Product) для TCP-канала:

$$\text{BDP} = B \cdot \text{RTT}, \quad (7)$$

определяет объём данных, одновременно находящихся «в полёте» при полной утилизации канала. Для внутренней сети датацентра с $B = 10$ Гбит/с и $\text{RTT} = 0.5$ мс:

$$\text{BDP} = \frac{10 \cdot 10^9}{8} \text{ Б/с} \times 0.5 \cdot 10^{-3} \text{ с} \approx 625 \text{ КБ}.$$

Это означает, что для полной утилизации 10G-канала размер TCP-окна должен быть не менее 625 КБ. Типичный размер чанка 8–64 МБ существенно превышает BDP, что позволяет одному TCP-соединению утилизировать канал без специальной настройки размера окна [39]. При переходе на 25G и 100G сети BDP возрастает пропорционально, и может потребоваться явная настройка `net.core.rmem_max` и `net.ipv4.tcp_rmem`.

4.8 Алгоритм чтения чанка

Полная тринадцатиступенчатая последовательность

Полный сценарий чтения чанка включает следующую последовательность шагов, охватывающую все три уровня архитектуры:

- а) ML-runtime (vLLM) вызывает `read(filepath, offset, size)`.
- б) Ядро Linux перехватывает вызов через VFS и передаёт `storage-mounter` через `/dev/fuse`.
- в) `storage-mounter` вычисляет диапазон чанков по формуле (6).
- г) `storage-mounter` отправляет запрос (`chunk_id`) локальному `storage-agent` через UDS.
- д) `storage-agent` проверяет локальное хранилище операцией `os.Stat` по физическому пути.
- е) **Сценарий А (local cache hit):** чанк найден на диске — данные читаются из файла и немедленно возвращаются через UDS.
- ж) **Сценарий В (local miss):** агент запрашивает Redis: `SMEMBERS chunk:<id>:peers`.

- и) Агент проверяет свежесть каждого кандидата: EXISTS node:<peer_id>.
- к) **Сценарий B.1 (peer cache hit):** выбирается пир с минимальным score; устанавливается TCP-соединение; чанк загружается; сохраняется атомарно на диск через os.Rename; агент регистрирует себя: SADD chunk:<id>:peers <local_node>.
- л) **Сценарий B.2 (peer miss, remote fallback):** список пиров пуст или все пиры недоступны; агент выполняет HTTP Range Request к HuggingFace; полученный чанк сохраняется и регистрируется в Redis.
- м) Чанк возвращается storage-mounter через UDS.
- н) storage-mounter собирает данные всех запрошенных чанков и вырезает нужный диапазон.
- п) Данные возвращаются через FUSE в ML-runtime.

Модель среднего времени доступа (AMAT)

Среднее время доступа к чанку описывается трёхуровневой моделью AMAT (Average Memory Access Time) [39]:

$$AMAT = T_{local} + (1 - H_l) [T_{p2p} + (1 - H_p) \cdot T_{remote}], \quad (8)$$

где:

- T_{local} — время чтения чанка из локального диска (сценарий A);
- H_l — вероятность попадания в локальный кэш (local hit rate);
- T_{p2p} — время получения чанка от соседнего агента по TCP (сценарий B.1);
- H_p — вероятность попадания в кэш соседних нод (peer hit rate);
- T_{remote} — время загрузки чанка из внешнего репозитория (сценарий B.2).

Вывод формулы (8) основан на формуле полного математического ожидания. С вероятностью H_l запрос обслуживается локально за время T_{local} . С вероятностью $(1 - H_l)$ происходит промах: система переходит на второй уровень, где с вероятностью H_p чанк находится у соседнего агента (T_{p2p}), и с вероятностью $(1 - H_p)$ требуется загрузка из внешнего источника (T_{remote}) [40]. Перемножение условных вероятностей даёт коэффициенты перед каждым слагаемым.

После прогрева кластера (первая загрузка популярной модели завершена) можно ожидать $H_l \approx 0.85$ и $H_p \approx 0.90$. Тогда доля запросов, достигающих внешнего источника:

$$(1 - H_l)(1 - H_p) = 0.15 \times 0.10 = 0.015.$$

Около 1.5% запросов уходят во внешний репозиторий, тогда как 98.5% обслуживаются из локального или соседнего кэша. Это кардинально отличается от схемы `storage-initializer`, при которой каждый новый под загружает модель целиком из внешнего источника. Поскольку T_{remote} может составлять десятки секунд для модели весом 70 ГБ, снижение его коэффициента с 1.0 до 0.015 является определяющим фактором ускорения cold start.

4.9 Политика кэширования и вытеснения

Распределение популярности моделей: закон Ципфа

Популярность моделей в реальных производственных системах распределена неравномерно: небольшое число наиболее востребованных моделей обеспечивает большую часть запросов. Аналогичная закономерность наблюдается в CDN (Content Delivery Networks), веб-кэшировании и системах хранения медиаконтента. Это распределение соответствует закону Ципфа [41]:

$$P(k) = \frac{k^{-\alpha}}{\sum_{i=1}^M i^{-\alpha}}, \quad (9)$$

где k — ранг модели по популярности (чем ниже ранг, тем популярнее), α — параметр наклона (для ML-моделей оценивается в диапазоне $\alpha \approx 0.8\text{--}1.2$ по публичным оценкам исследований веб-трафика), M — общее число моделей.

Закон Ципфа означает, что модель с рангом 1 запрашивается примерно в 2^α раз чаще модели с рангом 2. При $\alpha = 1$ и $M = 100$ моделях: топ-10 моделей (10%) генерируют более 60% запросов, топ-20 моделей — около 75%. Следствие для кэширования: даже кэш, вмещающий 20% самых популярных моделей, обеспечивает hit rate выше 75%. Нет необходимости хранить все существующие модели — достаточно приоритезировать наиболее запрашиваемые.

LRU как политика вытеснения

При превышении лимита дискового пространства применяется алгоритм LRU (Least Recently Used): вытесняются чанки, к которым дольше всего не было обращений. LRU хорошо согласуется с законом Ципфа: часто используемые модели (низкий ранг) регулярно обращаются к своим чанкам, обновляя метку «последнего использования», тогда как редко используемые (высокий ранг) постепенно вытесняются.

Практическая реализация LRU для файлового кэша: при обращении к чанку обновляется атрибут `atime` файла на диске (`O_NOATIME` отключён намеренно для отслеживания времени доступа). При необходимости вытеснения перебираются файлы в директории кэша, сортируются по `atime` по возрастанию, и удаляются до восстановления свободного места.

Аппроксимация Чи для оценки hit rate

Для приближённой оценки ожидаемого hit rate кэша размером C при распределении Ципфа применяется аппроксимация Чи (Che's approximation) [42]:

$$h(n) \approx 1 - e^{-\lambda_n t_C(C)}, \quad (10)$$

где λ_n — интенсивность запросов к n -й модели (определяется из (9) умножением на общую интенсивность запросов), $t_C(C)$ — характеристическое время кэша: при данном размере кэша C объект с интенсивностью запросов $\lambda_n > 1/t_C$ будет храниться с высокой вероятностью.

Аппроксимация Чи позволяет оценить совокупный hit rate для заданного размера кэша без полного моделирования трасс запросов. Это полезно при планировании дискового ресурса нод: можно заранее оценить, какой размер кэша на ноде (например, 200 ГБ или 1 ТБ NVMe) даст достаточный hit rate для ожидаемого распределения запросов.

4.10 Параллельная загрузка, выбор пира и prefetching

Алгоритм выбора пира

При наличии нескольких пиров, хранящих нужный чанк, система выбирает оптимальный узел для скачивания. Алгоритм выбора пира основан на следующих критериях, ранжированных по приоритету:

- а) **Свежесть heartbeat**: пир с истёкшим или отсутствующим heartbeat немедленно исключается (`EXISTS node:<peer_id> = 0`). Это защита от направления трафика к недоступным нодам.
- б) **Load score**: агент с меньшей вычислительной и сетевой нагрузкой предпочтительнее. Load score публикуется в heartbeat-записи Redis и обновляется каждые 10–30 с.
- в) **Локальность**: пир на той же стойке (rack) или в той же зоне доступности предпочтительнее за счёт меньшего RTT и более высокой пропускной способности внутрирячной сети.
- г) **Измеренный RTT**: периодические зондирующие запросы позволяют уточнить актуальную задержку до известных пиров.

Оценочная функция пира: $\text{score}(p) = \alpha \cdot \text{latency_ms}(p) + \beta \cdot \text{load}(p)$, где α и β — весовые коэффициенты, настраиваемые в конфигурации агента. Выбирается пир с минимальным score.

Параллельная загрузка и закон Амдала

Если несколько чанков модели отсутствуют в локальном кэше, и доступны несколько пиров, параллельная загрузка с разных пиров существенно сокращает общее время. Время параллельной загрузки [41]:

$$T_{\text{parallel}} = \frac{S}{B_{\text{total}}} + \text{RTT}, \quad (11)$$

где S — суммарный объём загружаемых данных, $B_{\text{total}} = \sum_{i=1}^k B_i$ — суммарная полоса пропускания k параллельных соединений, RTT — задержка установления соединений (пренебрежимо мала в датацентре).

Ускорение параллельной загрузки ограничено последовательными частями процесса — законом Амдала [43]:

$$S(n) = \frac{1}{(1-p) + p/n}, \quad (12)$$

где p — доля работы, поддающейся параллелизации (загрузка чанков), $(1-p)$ — последовательная часть (координация через Redis, сборка результата, инициализация FUSE). При $p = 0.9$ и $n = 4$ пирах:

$$S(4) = \frac{1}{0.1 + 0.225} = \frac{1}{0.325} \approx 3.1.$$

При $n = 16$ пирах: $S(16) \approx 5.8$. Предел при $n \rightarrow \infty$: $S_{\max} = 1/(1-p) = 10$. Таким образом, увеличение числа параллельных источников сверх 8–10 даёт убывающую отдачу, и оптимальное число пиров для параллельной загрузки — в диапазоне 4–8 для типичного датацентра с 10G-сетью.

Оптимальный размер чанка

Выбор размера чанка представляет собой задачу оптимизации с двумя конкурирующими составляющими. Функция суммарных накладных расходов на единицу данных:

$$f(C) = \frac{T_{\text{overhead}}}{C} + \frac{C}{B_{\text{net}}}, \quad (13)$$

где T_{overhead} — фиксированные накладные расходы на один чанк (переключение контекста FUSE, установка TCP-соединения, операции Redis), B_{net} — пропускная способность сети. Минимум функции (13) достигается при значении, найденном из условия нулевой производной $df/dC = 0$:

$$C_{\text{opt}} = \sqrt{T_{\text{overhead}} \cdot B_{\text{net}}}. \quad (14)$$

При $T_{\text{overhead}} = 1$ мс и $B_{\text{net}} = 10$ Гбит/с $= 1.25 \times 10^9$ Б/с:

$$C_{\text{opt}} = \sqrt{10^{-3} \times 1.25 \times 10^9} = \sqrt{1.25 \times 10^6} \approx 1118 \text{ КБ} \approx 1 \text{ МБ}.$$

Реальные накладные расходы T_{overhead} включают несколько компонент и в зависимости от конфигурации могут составлять от единиц до десятков миллисекунд; при $T_{\text{overhead}} = 10$ мс оптимальный размер чанка возрастает до ≈ 3.5 МБ. Диапазон 8–64 МБ, применяемый на практике, соответствует консервативной оценке накладных расходов с запасом для обеспечения

приемлемого time-to-first-byte.

Алгоритм prefetching

При последовательном паттерне чтения (характерном для загрузки весов модели слой за слоем в vLLM) storage-mounter применяет алгоритм упреждающей загрузки. После обслуживания запроса чанка k асинхронно запрашиваются чанки $k+1, k+2, \dots, k+N$, где N — размер окна prefetching. К моменту, когда ML-runtime запрашивает чанк $k+1$, он уже находится в локальном буфере storage-mounter. Сетевая задержка скрыта за временем обработки предыдущего чанка GPU-ядром.

Алгоритм обнаруживает последовательный паттерн за $O(1)$: достаточно сравнить текущее смещение с ожидаемым (предыдущее смещение + размер чанка). При обнаружении паттерна запускаются N параллельных горутин, каждая загружает один следующий чанк через UDS к storage-agent. Пространственная сложность буфера prefetching: $O(N \times C)$. Значение $N = 10$ при $C = 16$ МБ даёт буфер 160 МБ — приемлемо для типичной ноды.

4.11 Надёжность и высокая доступность

Формула доступности при репликации

Чанк считается доступным, если хотя бы одна нода, хранящая его, работоспособна. При факторе репликации r и вероятности доступности каждой ноды a :

$$A = 1 - (1 - a)^r. \quad (15)$$

При $a = 0.99$ и $r = 3$ репликах:

$$A = 1 - (0.01)^3 = 1 - 10^{-6} = 0.999999.$$

Вероятность одновременного отказа всех трёх реплик составляет 10^{-6} — один случай на миллион «нодо-дней» [44]. Для сравнения: NFS-сервер с доступностью $a = 0.999$ (три девятки) при $r = 1$ (нет репликации) обеспечивает ту же $A = 0.999$. Добавление репликации в P2P-архитектуре даёт шесть девяток без изменения доступности отдельной ноды.

Репликация в предложенной архитектуре возникает органически: как

только один агент загружает чанк из внешнего источника и регистрирует его в Redis, другие агенты могут найти его через SMEMBERS и при необходимости скачать копию. Администратор может задать минимальный фактор репликации для «горячих» моделей: агент при регистрации чанка проверяет, есть ли уже r пиров в `:peers`, и если нет — реплицирует самостоятельно.




Рисунок 3 – Простой в год в зависимости от коэффициента репликации чанков ($a = 0.99$). При $r = 3$ простой сокращается с 87.6 ч/год до 31.5 с/год — переход от двух к четырём девяткам доступности.

TTL как защита от stale metadata

TTL на Redis-записях автоматически устраняет stale metadata: если агент прекратил обновлять heartbeat, его записи исчезнут через TTL. Следующий запрос не будет направлен к этому агенту. Агент, обнаружив ошибку соединения с потенциальным пиром (ECONNREFUSED, ETIMEDOUT), немедленно исключает его из текущей операции и опционально выполняет `SREM chunk:<id>:peers <dead_node>` для ускорения очистки реестра.

Fallback и degraded mode

External fallback — загрузка из HuggingFace или другого внешнего репозитория — является конечной гарантией доступности. Пока внешний репозиторий доступен, система способна получить любой чанк, даже если

кластерный кэш полностью пуст. Fallback не является оптимальным по времени (десятки секунд для больших чанков), но обеспечивает корректность операции.

При временной недоступности Redis агент переключается в деградированный режим: обслуживает запросы только из локального кэша или через fallback, без P2P-координации. Это предотвращает полный сбой системы при проблемах с Redis и соответствует принципу graceful degradation.

Eventual consistency для метаданных

Redis-реестр обеспечивает eventual consistency для метаданных чанков. При добавлении новой ноды с чанками её записи становятся видимы другим агентам немедленно после успешного SADD. При удалении ноды её heartbeat-запись исчезнет через TTL. В промежутке между отказом ноды и истечением TTL её идентификатор присутствует в реестре, но попытка соединения вернёт ошибку, и агент корректно обработает её, выбрав следующий пир. Таким образом, eventual consistency в части метаданных не нарушает корректность алгоритма чтения — лишь добавляет задержку в крайне редких пограничных случаях.

4.12 Выводы по разделу

Разработанная архитектура P2P/FUSE-системы кэширования устраняет все ключевые ограничения NFS-этапа и формирует многоуровневую систему доступа к данным ML-моделей. Данные распределены по локальным дискам worker-нод, что исключает единую точку отказа и узкое место по пропускной способности: каждая нода читает чанки из локального кэша или получает их от нескольких соседних нод параллельно.

Redis heartbeat обеспечивает $O(1)$ -lookup активных агентов и доступных чанков — принципиальное преимущество перед eventual-consistent Gossip (задержка $O(\log N)$ раундов) при cold start. FUSE-клиент предоставляет ML-runtime стандартный POSIX-интерфейс без изменения кода инференс-фреймворков. Lazy loading позволяет начать обработку модели до завершения загрузки всех весов, перекрывая фазы вычисления и ввода-вывода.

Ключевые аналитические результаты раздела:

- Трёхуровневая модель АМАТ (8) при $H_l \approx 0.85$, $H_p \approx 0.90$ показывает, что более 98% запросов обслуживаются без обращения к внешнему репозиторию.
- Закон Амдала (12) при $p = 0.9$ ограничивает практический предел ускорения параллельной загрузки: оптимальное число пиров — 4–8, дальнейший рост числа параллельных источников даёт убывающую отдачу.
- Формула доступности (15) при $r = 3$ репликах на чанк и $a = 0.99$ даёт $A = 0.999999$ — шесть девяток надёжности.
- Разделение UDS (локальная коммуникация) и TCP (межндовая) оптимизирует как задержку (мкс-диапазон для UDS), так и надёжность (flow control TCP).

В совокупности перечисленные свойства формируют архитектуру, обеспечивающую существенное сокращение задержки cold start при повторных запусках одних и тех же ML-моделей в пределах кластера — характерном сценарии для производственных систем инференса.

5 ОЦЕНКА ЭФФЕКТИВНОСТИ И НАДЁЖНОСТИ ПРЕДЛОЖЕННОГО ПОДХОДА

В данном разделе описывается методика экспериментальной оценки предложенной архитектуры, формулируются метрики, строится расчётная модель задержки, анализируются ожидаемые результаты сравнения и рассматриваются ограничения подхода.

5.1 Методика экспериментов

Тестовый стенд

Для сравнительной оценки предлагается следующая конфигурация тестового стенда. Кластер состоит из 6 worker-нод на базе x86_64-серверов с процессорами Intel Xeon Silver (16 физических ядер, 32 потока), 64 ГБ ОЗУ и локальным NVMe-диск Samsung 980 Pro ёмкостью 2 ТБ (последовательная скорость чтения до 7000 МБ/с). Сеть между нодами — 10 Гбит/с Ethernet с коммутатором Top-of-Rack, RTT между нодами не превышает 0.5 мс.

Redis развёртывается в конфигурации Redis Sentinel: 1 master, 2 replica, автоматический failover при недоступности master. Размер чанка зафиксирован на уровне 16 МБ как компромисс между накладными расходами на метаданные (меньший чанк — больше записей в Redis) и гранулярностью параллельной загрузки (более крупный чанк снижает степень P2P-параллелизма).

Набор тестовых моделей включает: Llama 3 8B (≈ 15 ГБ, ≈ 960 чанков), Mistral 7B (≈ 14 ГБ, ≈ 896 чанков) и Llama 3 70B (≈ 140 ГБ, ≈ 8960 чанков). Для воспроизводимости результатов в отсутствие GPU runtime-контейнер заменяется синтетическим читателем, который последовательно читает все файлы модели через FUSE-точку монтирования и фиксирует время до первого байта и общее время чтения.

Процедура эксперимента

Каждый сценарий тестируется в двух режимах: *cold cluster* (дисковые кэши очищены, Redis пуст) и *warm cluster* (модель загружена хотя бы на одной ноде). В режиме *warm cluster* дополнительно разделяются сценарии: *warm on same node* (модель на ноде, где стартует под) и *warm on peer node* (модель на другой ноде кластера). Для *burst*-сценария одновременно

запускаются 10 подов на разных нодах, и измеряется суммарный внешний трафик и распределение $T_{\text{model_ready}}$ по репликам.

Сравниваемые сценарии

Сравниваются три подхода:

- а) **Baseline** (`storage-initializer + emptyDir`): каждый под независимо загружает всю модель из HuggingFace Hub через публичный интернет-канал. Представляет текущую практику в кластерах без выделенного кэша.
- б) **NFS**: общая директория монтируется через PVC/NFS. Первый под загружает модель из репозитория в NFS, остальные читают напрямую из общего тома. Представляет промежуточный подход, описанный в разделе 3.
- в) **P2P/FUSE** (предложенный подход): каждый под монтирует виртуальную файловую систему через `storage-mounter`; FUSE-операции транслируются в `chunk`-запросы к `storage-agent`. Агент обслуживает запросы из `local cache`, затем из `peer cache` (TCP к соседним агентам), и только при отсутствии чанков в кластере — из HuggingFace (`remote fallback`).

Каждый эксперимент повторяется не менее 5 раз; фиксируются медиана и 99-й перцентиль (p99) каждой метрики. Между экспериментами кэши очищаются или намеренно прогреваются в зависимости от измеряемого сценария. Результаты записываются средствами Prometheus и Grafana; временная метка создания пода берётся из Kubernetes Event API.

5.2 Метрики оценки

Для каждого сценария измеряются следующие метрики.

Время до первого байта $T_{\text{first_byte}}$ — интервал от момента создания пода (pod creation timestamp) до момента, когда runtime-контейнер успешно считал первый байт файла весов. Эта метрика критична для реализации `lazy loading`, при котором инференс может начаться до полной загрузки модели.

Время готовности модели $T_{\text{model_ready}}$ — полное время от создания пода до момента, когда синтетический читатель завершил последовательное чтение всех файлов модели. Для реального ML-runtime эквивалентно времени загрузки

весов в GPU-память.

Cache hit rate H_l определяется как доля запросов к storage-agent, обслуженных из локального дискового кэша:

$$H_l = \frac{N_{\text{local_hit}}}{N_{\text{local_hit}} + N_{\text{peer_hit}} + N_{\text{remote}}}$$

Peer hit rate H_p — доля запросов, удовлетворённых с соседних агентов по TCP:

$$H_p = \frac{N_{\text{peer_hit}}}{N_{\text{local_hit}} + N_{\text{peer_hit}} + N_{\text{remote}}}$$

Remote fallback rate $R = 1 - H_l - H_p$ — доля запросов, потребовавших обращения к внешнему репозиторию.

Внешний сетевой трафик V_{ext} — суммарный объём данных, скачанный из HuggingFace при масштабировании до N реплик. Для baseline: $V_{\text{ext}} = N \times S_{\text{model}}$; для P2P/FUSE в идеальном случае: $V_{\text{ext}} = S_{\text{model}}$ (однократная загрузка).

Redis lookup latency — время выполнения команд `SMEMBERS chunk:peers:{hash}` (поиск пиров для чанка) и `HGET agent:{id}` (получение адреса агента), измеренное как p50 и p99. Ожидаемые значения: $p50 < 1$ мс, $p99 < 5$ мс при развёртывании Redis в той же сети кластера [34].

CPU overhead FUSE — дополнительная нагрузка на CPU worker-ноды, вносимая FUSE-демоном storage-mounter, выраженная в процентах от доступных ядер при последовательном чтении 16-МБ чанков.

Задержка репликации чанка — время от момента записи чанка первым агентом до его появления в реестре Redis для других агентов. Включает время записи на NVMe, время команды `SADD` к Redis и RTT до Redis-сервера. Ожидаемое суммарное значение не превышает $T_l + \text{RTT}_{\text{Redis}} \approx 2.3 + 1 \approx 3.3$ мс.

5.3 Расчётная модель задержки

Трёхуровневая модель АМАТ

Среднее время доступа к данным (АМАТ, Average Memory Access Time) для трёхуровневой иерархии кэша [39] определяется формулой:

$$T_{\text{АМАТ}} = H_l \cdot T_l + (1 - H_l) [H_p \cdot T_p + (1 - H_p) \cdot T_r] \quad (16)$$

где T_l — время чтения из локального дискового кэша, T_p — время получения

чанка от соседнего агента по TCP, T_r — время загрузки чанка из внешнего репозитория, H_l и H_p — доли попаданий на каждом уровне.

Характерные значения компонентов задержки

Для NVMe-диска при последовательном чтении чанка размером 16 МБ:

$$T_l = \frac{16 \times 10^6 \text{ байт}}{7000 \times 10^6 \text{ байт/с}} \approx 2.3 \text{ мс}$$

Для P2P-передачи чанка по сети 10 Гбит/с с RTT 0.5 мс:

$$T_p = \frac{16 \times 10^6 \times 8 \text{ бит}}{10^{10} \text{ бит/с}} + \text{RTT} \approx 12.8 \text{ мс} + 0.5 \text{ мс} \approx 13.3 \text{ мс}$$

Для загрузки чанка из HuggingFace Hub через типичный канал 200 МБ/с (с учётом перегрузки сервера):

$$T_r = \frac{16 \times 10^6 \text{ байт}}{200 \times 10^6 \text{ байт/с}} + T_{\text{internet-RTT}} \approx 80 \text{ мс} + 50 \text{ мс} \approx 130 \text{ мс}$$

При перегруженном репозитории или медленном внешнем канале T_r может достигать 500–5000 мс.

Расчёт АМАТ при различных сценариях

Подставляя характерные значения $T_l \approx 2.3 \text{ мс}$, $T_p \approx 13.3 \text{ мс}$, $T_r \approx 130 \text{ мс}$ в формулу (16):

Таблица 6 – Расчётные значения АМАТ при разных уровнях hit rate

H_l	H_p	R	Описание сценария	АМАТ (мс)
0.00	0.00	1.00	Первый запуск, нет кэша	≈ 130
0.00	0.80	0.20	Нет локального, есть соседи	≈ 37
0.90	0.80	0.02	После прогрева кластера	≈ 4.3
0.99	0.80	0.002	Горячий кэш, популярная модель	≈ 2.5

Таблица 6 демонстрирует, что после прогрева кластера (hit rate 90%) среднее время доступа к чанку снижается примерно в 30 раз по сравнению со сценарием без кэша. При горячем кэше (hit rate 99%) достигается ускорение более чем в 50 раз.

Время загрузки модели и применение формулы P2P

Полное время загрузки модели размером S складывается из суммарного

АМАТ по всем чанкам. При $N_c = S/s$ чанках размером s и параллельной загрузке с k пиров [40]:

$$T_{\text{download}} = \frac{S}{B_{\text{local}} + \sum_{i=1}^k B_i} + \text{RTT} \quad (17)$$

где B_{local} — скорость чтения с локального диска, B_i — пропускная способность i -го пира.

Рассмотрим численный пример для модели Llama 3 8B ($S = 15$ ГБ):

- **Baseline:** $k = 0$, $B_{\text{local}} = 0$ (диск не используется), $B_{\text{HF}} = 200$ МБ/с.
 $T_{\text{download}} = 15000/200 \approx 75$ с.
- **Peer cache,** $k = 1$: $B_{\text{local}} = 1250$ МБ/с (10 Гбит/с).
 $T_{\text{download}} = 15000/1250 \approx 12$ с — ускорение в ≈ 6.3 раза.
- **Peer cache,** $k = 3$: суммарная пропускная способность $3 \times 1250 = 3750$ МБ/с, но ограничена входящим каналом ноды 1250 МБ/с. $T_{\text{download}} \approx 12$ с.
- **Local cache:** $B_{\text{local}} = 7000$ МБ/с (NVMe). $T_{\text{download}} = 15000/7000 \approx 2.1$ с — ускорение в ≈ 36 раз.

Таким образом, попадание в локальный кэш даёт наибольший выигрыш. При отсутствии локального кэша один пир обеспечивает ускорение в 6 раз по сравнению с загрузкой из внешнего репозитория.

Закон Амдала и предел параллельного ускорения

Параллельная загрузка чанков с нескольких пиров аналогична параллельному выполнению задачи. Закон Амдала [43] ограничивает максимальное ускорение $S(k)$:

$$S(k) = \frac{1}{\alpha + \frac{1-\alpha}{k}}$$

где α — доля последовательной части (Redis lookup, инициализация соединений), k — число параллельных пиров. При $\alpha = 0.05$ (5% последовательной части) и $k = 5$ пирах: $S(5) = 1/(0.05 + 0.19) \approx 4.2$. Таким образом, привлечение более 5 пиров даёт убывающую отдачу; практически оптимальным является диапазон $k = 2-4$ при балансе между параллелизмом и overhead на координацию.

Применение закона Литтла

Закон Литтла [18]:

$$L = \lambda \cdot W \quad (18)$$

позволяет оценить число одновременно ожидающих запросов. При интенсивности входящих запросов $\lambda = 5$ запр./с:

- Baseline ($W = 75$ с): $L = 5 \times 75 = 375$ ожидающих запросов.
- P2P/FUSE после прогрева ($W = 2.1$ с): $L = 5 \times 2.1 \approx 11$ ожидающих запросов.

Снижение числа ожидающих запросов в ≈ 34 раза непосредственно транслируется в снижение нагрузки на очередь и улучшение соблюдения SLA по задержке ответа.

5.4 Ожидаемые результаты сравнения

Таблица 7 – Сравнение подходов по ключевым показателям

Показатель	emptyDir	NFS	P2P/FUSE
$T_{\text{model_ready}}$, первый запуск	≈ 75 с	≈ 75 с	≈ 75 с (fallback)
$T_{\text{model_ready}}$, повтор на той же ноте	≈ 75 с	≈ 12 с	≈ 2 с (local cache)
$T_{\text{model_ready}}$, повтор на соседней ноте	≈ 75 с	≈ 12 с	≈ 12 с (peer cache)
$T_{\text{first_byte}}$	≈ 75 с	≈ 75 с	< 1 с (lazy FUSE)
Внешний трафик, $N = 10$ реплик	$10 \times 15 = 150$ ГБ	15 ГБ	≤ 15 ГБ
SPOF	Нет	NFS-сервер	Redis (с HA — нет)
Деградация при отказе	Нет	Полная	Graceful (local+fallback)
Сложность эксплуатации	Низкая	Средняя	Средняя

Ключевым преимуществом P2P/FUSE-подхода является значение $T_{\text{first_byte}} < 1$ с: FUSE-монтаж позволяет runtime-контейнеру начать чтение сразу после запуска, тогда как физическая загрузка чанков происходит параллельно с чтением (lazy loading). Для baseline и NFS время до первого байта совпадает с полным временем загрузки, поскольку storage-initializer должен завершить скачивание до старта основного

контейнера.

По показателю внешнего трафика P2P/FUSE при прогревом кластере эквивалентен NFS: загрузка происходит один раз. При этом данные распределяются по дискам всех нод, создавая избыточность без выделенного NFS-сервера.




Рисунок 4 – Время готовности модели ($T_{\text{model_ready}}$) по сценариям для Llama 3 8B (15 ГБ). При наличии локального кэша P2P/FUSE-подход обеспечивает $T_{\text{model_ready}} = 1.9$ с против 74.8 с у baseline.

5.5 Анализ сценариев отказов

Падение worker-ноды с чанками

При отказе ноды агент перестаёт обновлять TTL-записи в Redis. По истечении TTL (типично 30 с) записи удаляются. При запросе затронутого чанка агент соседней ноды получает пустой список пиров для данного чанка и инициирует fallback на HuggingFace. Деградация ограничена временем T_{TTL} и затрагивает только чанки, хранившиеся исключительно на упавшей ноды. При репликации каждого чанка на $r \geq 2$ ноды вероятность потери доступности:

$$P_{\text{unavail}} = p^r$$

где p — вероятность отказа одной ноды. При $p = 0.01$ и $r = 2$: $P_{\text{unavail}} = 10^{-4}$; при $r = 3$: $P_{\text{unavail}} = 10^{-6}$ [44].

Устаревшая запись в Redis (stale metadata)

Агент пытается подключиться к указанному пиру, получает ошибку




Рисунок 5 – Суммарный внешний трафик при масштабировании до N реплик (Llama 3 8B, 15 ГБ). Подходы NFS и P2P/FUSE загружают модель однократно независимо от числа реплик; emptyDir генерирует $N \times 15$ ГБ трафика.

соединения, переходит к следующему пиру из множества `chunk:peers:{hash}` или инициирует `fallback`. Stale-записи автоматически удаляются по TTL, не требуя ручного вмешательства.

Недоступность Redis

При недоступности Redis агент теряет возможность находить пиры. Система деградирует до двухуровневой: `local cache` → `remote fallback`. Обслуживание запросов продолжается при наличии локальных данных. При развёртывании Redis Sentinel (1 master, 2 replica) вероятность одновременного отказа всех узлов пренебрежимо мала при независимых отказах [34].

Недоступность HuggingFace Hub

Система использует данные из `local` и `peer cache`. Новые модели, ещё не загруженные в кластер, становятся недоступны. Это является ожидаемой деградацией при условии предварительного прогрева популярных моделей. Возможным улучшением является поддержка зеркальных репозиторий в качестве альтернативных источников `fallback`.

Частичная запись чанка (crash во время записи)

При аварийном завершении агента в процессе записи чанка временный файл (с суффиксом `.tmp`) не переименовывается в финальный путь. При следующем запросе агент не найдёт чанк в локальном хранилище и повторит загрузку. Консистентность обеспечивается атомарностью системного вызова `os.Rename`, который переименовывает файл только при успешном завершении записи.

Сетевое разбиение кластера

При разбиении кластера на изолированные части агенты, не имеющие доступа к Redis master, переходят в degraded-режим: local cache + remote fallback. После восстановления сетевой связности агенты возобновляют heartbeat, и Redis автоматически обновляет реестр активных пиров.




Рисунок 6 – Деградация инференса при трёх сценариях отказов (прогретый кластер, $r = 3$). NFS полностью теряет доступ при отказе сервера или HF Hub; P2P/FUSE деградирует до 15% при недоступности Redis и остаётся полностью работоспособен при сбое HF Hub.

5.6 Ограничения предложенного подхода

Накладные расходы FUSE. Каждая операция чтения проходит через два context switch: пользовательское пространство $\rightarrow$ ядро (VFS-перехват) $\rightarrow$ пользовательское пространство (FUSE-демон). Для ML-workload с последовательными крупными чтениями (размер чанка 16 МБ)

эти накладные расходы незначительны: при 2 context switch по ≈ 5 мкс каждый и времени чтения чанка ≈ 2.3 мс суммарные накладные расходы не превышают 0.5%. Для сценариев случайного доступа по малым диапазонам (например, чтение отдельных тензоров модели) относительные накладные расходы возрастают.

Redis как критический компонент. Без HA-конфигурации Redis является SPOF для функции peer discovery. Данные при этом не теряются: система деградирует до local + fallback, сохраняя частичную работоспособность. HA-конфигурация (Sentinel или Cluster) устраняет эту единственную точку отказа на уровне сигнализации.

Сложность наблюдаемости. P2P-трафик менее прозрачен, чем чтение из NFS. Для корректного мониторинга требуется сбор метрик: счётчики local hit/miss, peer hit/miss, remote fallback; задержки по уровням; состояние Redis; объём данных на каждой ноде. Без инструментирования диагностика деградации производительности затруднена.

Первый запуск в кластере. При полном отсутствии кэша (cold cluster) система вынуждена загружать модель из внешнего репозитория. Выигрыш появляется начиная со второго запуска. Возможным улучшением является предварительное прогревание кэша (cache warming) в периоды низкой нагрузки.

Малые модели. Для моделей размером до 1 ГБ накладные расходы на FUSE, Redis и P2P-координацию могут быть сравнимы с временем прямой загрузки через emptyDir. Архитектура наиболее эффективна для LLM и других крупных моделей (> 5 ГБ).

Безопасность. В текущем прототипе TCP-соединения между агентами не аутентифицированы. В production-окружении необходима поддержка mTLS между агентами, авторизация запросов к Redis через ACL и шифрование трафика.

5.7 Выводы по разделу

Расчётная модель AMAT и анализ формулы P2P-загрузки демонстрируют, что предложенная архитектура наиболее эффективна в сценариях повторных запусков и burst-масштабирования. При прогревом кластера (hit rate 90%) среднее время доступа к чанку снижается в 30 раз по сравнению с постоянным обращением к внешнему репозиторию, а полное

время загрузки модели — с 75 с до 2 с при попадании в локальный кэш. Механизм FUSE lazy loading обеспечивает время до первого байта менее 1 с, что принципиально недостижимо при storage-initializer-подходе. Анализ сценариев отказов показывает, что система деградирует gracefully: потеря worker-ноды затрагивает только нерезервированные чанки, а недоступность Redis переводит систему в двухуровневый режим с сохранением работоспособности. Ключевые ограничения — FUSE overhead при мелком доступе, требование HA Redis и сложность наблюдаемости — известны и могут быть устранены на следующих этапах разработки.

ЗАКЛЮЧЕНИЕ

В данной работе исследована проблема холодного старта при развёртывании моделей машинного обучения в бессерверном инференсе на базе Kubernetes, а также разработана специализированная архитектура распределённого кэширования для её решения.

Выполненные задачи. В ходе работы последовательно решены все поставленные задачи.

Задача 1: анализ причин холодного старта. Установлено, что рост размеров ML-моделей — с сотен мегабайт у CNN-архитектур до сотен гигабайт у современных LLM — превратил этап загрузки весов из второстепенной детали в доминирующую составляющую задержки холодного старта. Применение закона Литтла показало, что при типичных нагрузках задержка в 75 с при $\lambda = 5$ запр./с порождает очередь из 375 ожидающих запросов, что делает scale-to-zero практически неприменимым без специальной оптимизации.

Задача 2: исследование существующих решений. Проведённый сравнительный анализ Alluxio, JuiceFS, Dragonfly, CubeFS и Rook/Ceph показал, что ни одна из систем не удовлетворяет в полной мере специфике задачи: Alluxio избыточно сложен и требует коммерческой лицензии для enterprise-возможностей, JuiceFS требует объектного хранилища как обязательной зависимости, Dragonfly лишён POSIX-интерфейса. Это обосновало необходимость специализированной разработки.

Задача 3: промежуточное NFS-решение. Разработано промежуточное решение на базе NFS, устранившее проблему повторных загрузок из внешнего репозитория. Первый pod скачивает модель, остальные читают из общей директории. Разработаны алгоритмы координации с использованием flock и Kubernetes Lease. Однако NFS создал новый SPOF и bottleneck пропускной способности, что потребовало следующего этапа.

Задача 4: механизмы координации в Kubernetes. Исследованы файловые блокировки (flock), ресурс Lease из Coordination API и алгоритм Leader Election из библиотеки client-go. Установлено, что per-model Lease обеспечивает надёжную координацию первой загрузки модели без состояния гонки, однако не устраняет centralized-чтение через NFS.

Задача 5: архитектура распределённого chunk-кэша. Спроектирована

трёхуровневая схема доступа: local cache → peer cache → remote fallback. Каждая worker-нода хранит чанки модели на локальном NVMe-диске. При запросе чанка агент проверяет локальное хранилище, затем обращается к Redis за списком пиров, затем загружает чанк из внешнего репозитория.

Задача 6: Redis как реестр метаданных. Обосновано применение Redis с TTL-based heartbeat в качестве централизованного реестра активных агентов и доступных чанков. Показано, что Redis обеспечивает $O(1)$ -поиск пиров с задержкой менее 1 мс, что значительно быстрее gossip-конвергенции и надёжнее mDNS в overlay-сетях Kubernetes.

Задача 7: применение FUSE. Обоснован выбор FUSE для предоставления ML-runtime стандартного файлового интерфейса. Механизм VFS-перехватов позволяет реализовать lazy loading: runtime-контейнер начинает чтение файла модели немедленно, тогда как физическая загрузка чанков происходит по мере обращений. Время до первого байта составляет менее 1 с.

Задача 8: разделение UDS и TCP. Формализовано применение Unix Domain Socket для канала storage-mounter → storage-agent (нулевые накладные расходы на сетевой стек, доступен только на одной ноде) и TCP для межнодового канала storage-agent → storage-agent (совместимость с Kubernetes networking, поддержка mTLS).

Задача 9: реализация прототипа. Реализованы ключевые компоненты: storage-mounter с FUSE-файловой системой на базе go-fuse, локальным chunk-кэшем и интерфейсом к HuggingFace Hub; storage-agent с chunk-cache на файловой системе и fallback-загрузкой. Прототип верифицирует архитектурную концепцию и служит основой для производственной реализации.

Задача 10: методика оценки эффективности. Построена расчётная модель на базе AMAT, показывающая ускорение доступа к чанку в 30–50 раз при прогревом кластере. Проведён анализ пяти ключевых сценариев отказов с описанием механизмов graceful degradation. Выявлены ограничения и определены направления дальнейшего развития.

Практическая ценность. Предложенная архитектура обеспечивает ряд практически значимых результатов. Во-первых, снижается внешний трафик к модельным хабам: при N репликах вместо $N \times S_{\text{model}}$ байт передаётся S_{model} — однократная загрузка независимо от числа реплик. Для модели 15 ГБ и 10

реплик экономия составляет 135 ГБ внешнего трафика за одно burst-событие. Во-вторых, ускоряется повторный старт: попадание в локальный NVMe-кэш обеспечивает время загрузки модели ≈ 2 с против 75 с при загрузке из интернета. В-третьих, устраняется NFS как SPOF: распределённый кэш не имеет единого сервера, деградация затрагивает только ноды с отказами. В-четвёртых, сохраняется полная совместимость с любым ML-runtime без изменения его кода: FUSE предоставляет стандартный файловый интерфейс.

Ограничения. Система наиболее эффективна для крупных моделей (>5 ГБ); для малых моделей накладные расходы на FUSE и Redis могут превышать выигрыш от кэширования. Первый запуск в незаполненном кластере требует полной загрузки из внешнего репозитория. Redis в базовой конфигурации остаётся точкой отказа для функции peer discovery (устраняется HA-конфигурацией). P2P-трафик между агентами требует инструментирования для корректной наблюдаемости.

Направления дальнейшего развития. На основе анализа реализованного прототипа и выявленных ограничений определены следующие направления развития:

- Полная реализация Redis-реестра в коде `storage-agent`: регистрация чанков после загрузки, heartbeat-обновление TTL-записей, поиск пиров при cache miss.
- Реализация P2P-чтения между агентами по TCP с поддержкой параллельной загрузки чанков с нескольких пиров одновременно.
- Реализация UDS-транспорта для канала `storage-mounter` → `storage-agent` с устранением накладных расходов сетевого стека.
- Добавление LRU/TTL-политики вытеснения чанков с учётом популярности моделей по закону Ципфа.
- Реализация prefetching: при обнаружении последовательного паттерна чтения агент заблаговременно загружает следующие чанки.
- Добавление контрольных сумм (SHA-256) для верификации целостности чанков при P2P-передаче.
- Поддержка mTLS между агентами для обеспечения аутентификации в production-окружении.
- Расширение источников данных: Ollama Hub, ModelScope, S3-совместимое хранилище.

- Проведение полноценного benchmark на production-кластере с реальными GPU-нагрузками и измерением $T_{\text{model_ready}}$ для актуальных LLM-моделей.

Полученные результаты подтверждают, что предложенный подход позволяет существенно сократить задержку холодного старта ML-инференса в Kubernetes, сохраняя преимущества serverless-масштабирования и обеспечивая отказоустойчивость без единой точки отказа.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding / J. Devlin [и др.]. — 2018. — arXiv:1810.04805.
2. Meta AI. Llama 3: Open Foundation Language Models. — 2024. — <https://llama.meta.com/llama3/>.
3. Technology Innovation Institute. Falcon-180B: A Large Language Model. — 2023. — <https://falconllm.tii.ae>.
4. Otus Blog. LLM Capability Density doubles every 3.5 months. — 2024. — <https://habr.com/ru/companies/otus/news/971414/>.
5. Knative Authors. Knative: Kubernetes-based platform to deploy and manage modern serverless workloads. — 2024. — <https://knative.dev>.
6. KServe Authors. KServe: Standardized Model Inference Platform on Kubernetes. — 2024. — <https://kserve.github.io/website/>.
7. BentoML Team. 25x Faster Cold Starts for LLMs on Kubernetes. — 2024. — <https://www.bentoml.com/blog/25x-faster-cold-starts-for-llms-on-kubernetes>.
8. Krizhevsky A., Sutskever I., Hinton G. E. ImageNet classification with deep convolutional neural networks // Advances in Neural Information Processing Systems. T. 25. — Curran Associates, Inc., 2012.
9. Language Models are Few-Shot Learners / T. B. Brown [и др.]. — 2020. — arXiv:2005.14165.
10. DeepSeek-AI. DeepSeek-V2: A Strong, Economical, and Efficient Mixture-of-Experts Language Model. — 2024. — arXiv:2405.04434; <https://huggingface.co/deepseek-ai/DeepSeek-V2>.
11. Z.ai. GLM-4.5. — 2025. — <https://huggingface.co/zai-org/GLM-4.5>.
12. DeepSeek-AI. DeepSeek-V4-Pro. — 2026. — <https://huggingface.co/deepseek-ai/DeepSeek-V4-Pro>.
13. Language Models are Unsupervised Multitask Learners / A. Radford [и др.]. — 2019. — OpenAI Technical Report, https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf.

14. Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer / C. Raffel [и др.] // Journal of Machine Learning Research. — 2020. — Т. 21, № 140. — С. 1—67.
15. LLaMA: Open and Efficient Foundation Language Models / H. Touvron [и др.]. — 2023. — arXiv:2302.13971.
16. Llama 2: Open Foundation and Fine-Tuned Chat Models / H. Touvron [и др.]. — 2023. — arXiv:2307.09288.
17. Mistral AI. Mixtral 8x22B: Cheaper, Faster, Stronger. — 2024. — <https://mistral.ai/news/mixtral-8x22b/>.
18. Little J. D. C. A Proof for the Queuing Formula: $L = \lambda W$ // Operations Research. — 1961. — Т. 9, № 3. — С. 383—387.
19. Alluxio, Inc. Alluxio Architecture Overview. — 2024. — <https://documentation.alluxio.io/os-en/overview-1/architecture>.
20. Alluxio, Inc. Alluxio on Kubernetes. — 2024. — <https://www.alluxio.io/kubernetes>.
21. Alluxio, Inc. Alluxio Pricing and Editions. — 2024. — <https://www.alluxio.io/pricing>.
22. Juicedata, Inc. JuiceFS Introduction. — 2024. — <https://juicefs.com/docs/community/introduction/>.
23. Juicedata, Inc. JuiceFS Technical Architecture. — 2024. — <https://juicefs.com/en/blog/engineering/design-metadata-data-storage>.
24. Juicedata, Inc. JuiceFS Performance Optimization for AI Scenarios. — 2024. — <https://juicefs.com/en/blog/engineering/juicefs-ai-workload-performance-optimization>.
25. Alibaba Cloud. P2P-Based Intelligent Image Acceleration System of Dragonfly. — 2023. — https://www.alibabacloud.com/blog/p2p-based-intelligent-image-acceleration-system-of-dragonfly_599645.
26. CubeFS Authors. CubeFS Architecture. — 2024. — <https://cubefs.io/docs/master/overview/architecture.html>.

27. Rook Authors. Rook Documentation. — 2024. — <https://rook.io/docs/rook/latest-release/>.
28. Ceph Foundation. Ceph Architecture. — 2024. — <https://docs.ceph.com/en/reef/architecture>.
29. Kubernetes Authors. Configure a Pod to Use a PersistentVolume for Storage. — 2024. — <https://kubernetes.io/docs/tasks/configure-pod-container/configure-persistent-volume-storage/>.
30. Linux Programmer's Manual. flock(2) Linux man page. — 2024. — <https://man7.org/linux/man-pages/man2/flock.2.html>.
31. Kubernetes Authors. Kubernetes Coordination API: Lease. — 2024. — <https://kubernetes.io/docs/reference/kubernetes-api/cluster-resources/lease-v1/>.
32. Brewer E. A. Towards robust distributed systems // Proceedings of the Annual ACM Symposium on Principles of Distributed Computing (PODC). — 2000. — Keynote address.
33. Redis Labs. Redis Cluster Specification. — 2024. — <https://redis.io/docs/reference/cluster-spec/>.
34. Redis Labs. Redis Sentinel High Availability. — 2024. — <https://redis.io/docs/management/sentinel/>.
35. Renesse R. van, Minsky Y., Hayden M. Gossip Protocol in Distributed Systems. — 1998. — Cornell University Technical Report.
36. CNCF Networking Working Group. Multicast DNS and Kubernetes Overlay Networks. — 2023. — <https://github.com/cncf/sig-network>.
37. Szeredi M. FUSE: Filesystem in Userspace // Linux Symposium. — 2010. — C. 267—278.
38. Shu H. go-fuse: FUSE bindings for Go. — 2024. — <https://github.com/hanwen/go-fuse>.
39. Hennessy J. L., Patterson D. A. Computer Architecture: A Quantitative Approach. — 5th. — Morgan Kaufmann, 2011.

40. Caching Structures for Distributed Data Management in Edge Computing / J. Li [и др.] // IEEE Access. — 2020. — Т. 8. — С. 152—163.
41. Zipf G. K. Human Behavior and the Principle of Least Effort. — 1949.
42. Che S., Mandjes M., Bonald T. Revisiting the TTL-based approximation for the LRU cache // Proceedings of IEEE INFOCOM. — 2002.
43. Amdahl G. M. Validity of the single processor approach to achieving large scale computing capabilities // Proceedings of the AFIPS Spring Joint Computer Conference. — 1967. — С. 483—485.
44. Availability in Globally Distributed Storage Systems / D. Ford [и др.] // 9th USENIX Symposium on Operating Systems Design and Implementation (OSDI). — 2010. — С. 61—74.