



МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(национальный исследовательский университет)»

ЗАКЛЮЧЕНИЕ РЕЦЕНЗЕНТА О ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЕ

Обучающийся Блинов Максим Алексеевич

Институт (Филиал) № 8 «Компьютерные науки и прикладная математика»

Образовательный центр института № 8

Группа М8О-209СВ-24 Направление подготовки 02.04.02 «Фундаментальная информатика и информационные технологии»

Профиль Искусственный интеллект и суперкомпьютерные технологии

Квалификация: инженер-исследователь

Наименование темы Оптимизация холодного старта и масштабирования моделей машинного обучения в бессерверном инференсе для обеспечения высокой доступности

Рецензент Ахмед Самир Халид, руководитель отдела R&D, ООО «Ай Кью Тулс»

Отмеченные достоинства: Выпускная квалификационная работа посвящена актуальной задаче сокращения времени холодного старта и повышения доступности бессерверного инференса моделей машинного обучения в *Kubernetes*-среде. Актуальность выбранной темы обусловлена тем, что при использовании *serverless*-подхода значительная часть задержки первого запроса переносится из вычислительного контура в контур доставки данных, а рост объёма весов современных моделей делает повторную загрузку артефактов всё более затратной по времени и по внешнему трафику. Автор корректно формулирует исходное противоречие между требованиями к быстрому масштабированию и экономией ресурсов за счёт *scale-to-zero*. Сильной стороной работы является логично выстроенная последовательность инженерного анализа. Особо следует отметить практическую направленность диссертации. В работе не ограничиваются общими архитектурными рассуждениями: рассмотрены вопросы кэширования, репликации чанков, времени жизни метаданных и поведения системы при *cache miss*; проведено сопоставление предложенного подхода с *emptyDir* и *NFS*-сценариями по времени подготовки новых реплик, нагрузке на внешний источник и устойчивости к *burst*-нагрузке. Это позволяет сделать вывод о хорошей связи между теоретическим анализом, проектными решениями и их экспериментальной проверкой.

Отмеченные недостатки: Экспериментальную часть целесообразно расширить за счёт

большого числа моделей и более длительных нагрузочных сценариев. Дополнительного анализа также требует поведение системы при сетевых разбиениях и дальнейшем росте числа узлов кластера.

Заключение: Работа выполнена на высоком научно-техническом уровне, сочетает анализ предметной области, проектирование распределённой архитектуры и обоснование её эффективности. Отмеченные недостатки носят рекомендательный характер. Работа удовлетворяет требованиям, предъявляемым к выпускным квалификационным работам по направлению «Фундаментальная информатика и информационные технологии», а автор Блинов М. А. заслуживает оценки «отлично» и присвоения квалификации инженер-исследователь.

_____ 2026г.

Рецензент _____