



МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(национальный исследовательский университет)»

ОТЗЫВ НАУЧНОГО РУКОВОДИТЕЛЯ

Обучающийся Блинов Максим Алексеевич

Институт (Филиал) № 8 «Компьютерные науки и прикладная математика»

Образовательный центр № 806

Группа М8О-209СВ-24 **Направление подготовки** 02.04.02 «Фундаментальная информатика и информационные технологии»

Профиль Искусственный интеллект и суперкомпьютерные технологии

Квалификация: инженер-исследователь

Наименование темы Оптимизация холодного старта и масштабирования моделей машинного обучения в бессерверном инференсе для обеспечения высокой доступности

Руководитель Булакина Мария Борисовна

Работа проверена на объем заимствования. % заимствования – %

Выпускная квалификационная работа посвящена актуальной задаче сокращения времени холодного старта и повышения доступности бессерверного инференса моделей машинного обучения в Kubernetes-среде. Значимость темы определяется тем, что при использовании serverless-подхода задержка первого запроса всё в большей степени зависит не от запуска контейнера как такового, а от времени доставки больших файлов модели. В работе корректно сформулировано противоречие между необходимостью быстро масштабировать inference-сервис и стремлением снизить инфраструктурные затраты за счёт scale-to-zero. К числу существенных достоинств работы следует отнести последовательный характер исследования: автор не ограничивается описанием итоговой архитектуры, а показывает эволюцию решения от исходной схемы storage-initializer + emptyDir к промежуточному варианту на базе NFS и далее к распределённому подходу с использованием локальных дисков узлов, Redis-реестра метаданных, storage-agent и storage-mounter. Такой способ изложения позволяет увидеть, какие именно ограничения предыдущих решений послужили основанием для перехода к новой архитектуре. Особо следует отметить практическую направленность выполненной работы. В рамках ВКР предложены и описаны конкретные инженерные механизмы: разбиение модели на чанки, локальное кэширование, межузловой обмен данными, fallback-загрузка из внешнего источника, использование FUSE для прозрачного файлового доступа со стороны runtime. Важным достоинством является и то, что предложенный подход совместим с существующими ML-runtime и не требует

изменения прикладного программного обеспечения. Экспериментальная часть связывает архитектурные решения с наблюдаемыми эффектами по времени подготовки новых реплик, внешнему трафику и устойчивости к burst-нагрузке. В ходе выполнения работы автор продемонстрировал способность самостоятельно разбираться в сложной предметной области, сопоставлять альтернативные архитектурные подходы, аргументированно принимать проектные решения и аккуратно оформлять результаты исследования. Вместе с тем работа может быть дополнительно усилена в нескольких направлениях: прежде всего, экспериментальную часть целесообразно расширить за счёт большего набора моделей, отличающихся по размеру и профилю чтения, а также за счёт более длительных нагрузочных сценариев; дополнительного исследования требует влияние коэффициента репликации, размера чанка и политики вытеснения на эффективность системы при неравномерном распределении популярности моделей; кроме того, отдельного анализа заслуживает поведение архитектуры при сетевых разбиениях и временной недоступности сервисов метаданных. В целом выпускная квалификационная работа выполнена на высоком уровне, сочетает актуальную постановку задачи, системный анализ предметной области, последовательное проектирование архитектуры и практическую проверку предложенного подхода. Сделанные замечания носят рекомендательный характер и не снижают общей положительной оценки выполненной работы. Работа соответствует требованиям, предъявляемым к выпускным квалификационным работам по направлению «Фундаментальная информатика и информационные технологии», а автор Блинов М. А. заслуживает оценки «отлично» и присвоения квалификации инженер-исследователь.

_____ 2026г.

Руководитель _____