



МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(национальный исследовательский университет)»

Институт (Филиал) № 8 «Компьютерные науки и прикладная математика»

Кафедра 806

Группа М8О-109СВ-24 Направление подготовки 02.04.02 «Фундаментальная информатика и информационные технологии»

Профиль Искусственный интеллект и суперкомпьютерные технологии

Квалификация: инженер-исследователь

УТВЕРЖДАЮ

Директор Дирекции Института № 8 _____ С.С. Крылов
_____ 2026г.

ЗАДАНИЕ
на выпускную квалификационную работу

Обучающийся Блинов Максим Алексеевич

Руководитель Булакина Мария Борисовна

1. Наименование темы Оптимизация холодного старта и масштабирования моделей машинного обучения в бессерверном инференсе для обеспечения высокой доступности

2. Срок сдачи обучающимся законченной работы 24.05.2026

3. Задание и исходные данные к работе

Провести анализ причин холодного старта моделей машинного обучения в бессерверном *inference Kubernetes*, исследовать существующие решения для совместного хранения и кэширования весов моделей, разработать и обосновать архитектуру распределённого кэширования с этапом *NFS* и целевой *P2P/FUSE*-системой, реализовать компоненты *storage-agent* и *storage-mounter*, выполнить нагрузочное сравнение с подходами *emptyDir* и *NFS*. Исходными данными являются публикации по *serverless ML inference*, распределённым файловым системам и кэшированию, исходный код реализованных компонентов, результаты экспериментального тестирования и материалы итоговой презентации.

Перечень иллюстративно-графических материалов:

№ п/п	Наименование	Количество листов (слайдов)
1	Титульный слайд	1
2	Обоснование актуальности темы работы	2
3	Цель и задачи работы	1
4	Исходная архитектура и постановка задачи	2
5	Существующие решения	1
6	Требования к архитектуре	1
7	Используемые технологии	1
8	Архитектура решения	1
9	Нагрузочное тестирование и экспериментальное сравнение	5
10	Итоги работы и направления дальнейшего развития	2

4. Перечень подлежащих разработке разделов и этапы выполнения работы

№ п/п	Наименование раздела или этапа	Трудоёмкость в % от полной трудоёмкости ВКР	Срок выполнения	Примечание
1	Анализ литературы и предметной области	12	02.09.2024–30.11.2024	
2	Постановка задачи и формирование требований к архитектуре	10	01.12.2024–31.01.2025	
3	Проектирование и внедрение этапа с использованием NFS	18	01.02.2025–31.05.2025	
4	Анализ ограничений NFS и разработка целевой P2P/FUSE-архитектуры	18	01.06.2025–30.09.2025	
5	Разработка storage-agent, Redis-реестра и механизмов репликации чанков	16	01.10.2025–31.12.2025	
6	Разработка storage-mounter и интеграция с ML-runtime	14	01.01.2026–29.02.2026	
7	Нагрузочное тестирование, анализ результатов и оформление ВКР	12	01.03.2026–24.05.2026	

5. Исходные материалы и пособия

DeepSeek-AI. DeepSeek-V4-Pro. 2026; Kubernetes Authors. Configure a Pod to Use a PersistentVolume for Storage. 2024; Redis Labs. Redis Cluster Specification. 2024; Szeredi M. FUSE: Filesystem in Userspace // Linux Symposium. 2010. P. 267–278; Kubernetes Authors. DaemonSet in Kubernetes. 2024.

6. Дата выдачи задания 02.09.2024

Руководитель _____

Задание принял к исполнению _____