



**МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ**

**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(национальный исследовательский университет)»**

Институт (Филиал) № 8 «Компьютерные науки и прикладная математика»

Кафедра 806

Группа М8О-109СВ-24 Направление подготовки 02.04.02 «Фундаментальная информатика и информационные технологии»

Профиль Искусственный интеллект и суперкомпьютерные технологии

Квалификация: инженер-исследователь

УТВЕРЖДАЮ

Директор Дирекции Института № 8 _____ С.С. Крылов

_____ 2026г.

**ЗАДАНИЕ
на выпускную квалификационную работу**

Обучающийся Блинов Максим Алексеевич

Руководитель Булакина Мария Борисовна

1. Наименование темы Оптимизация холодного старта и масштабирования моделей машинного обучения в бессерверном инференсе для обеспечения высокой доступности

2. Срок сдачи обучающимся законченной работы 24.05.2026

3. Задание и исходные данные к работе

Провести анализ причин холодного старта моделей машинного обучения в бессерверном инференсе Kubernetes, исследовать существующие решения для совместного хранения и кэширования весов моделей, разработать и обосновать архитектуру распределённого кэширования с этапом NFS и целевой P2P/FUSE-системой, реализовать компоненты storage-agent и storage-mounter, выполнить нагрузочное сравнение с подходами emptyDir и NFS. Исходными данными являются публикации по serverless ML inference, распределённым файловым системам и кэшированию, исходный код реализованных компонентов, результаты экспериментального тестирования и материалы итоговой презентации.

Перечень иллюстративно-графических материалов:

№ п/п	Наименование	Количество листов (слайдов)
1	Титульный слайд	1
2	Обоснование актуальности темы работы	2
3	Цель и задачи работы	1
4	Исходная архитектура и постановка задачи	2
5	Существующие решения	1
6	Требования к архитектуре	1
7	Используемые технологии	1
8	Архитектура решения	1
9	Нагрузочное тестирование и экспериментальное сравнение	5
10	Итоги работы и направления дальнейшего развития	2

4. Перечень подлежащих разработке разделов и этапы выполнения работы

№ п/п	Наименование раздела или этапа	Трудоёмкость в % от полной трудоёмкости ВКР	Срок выполнения	Примечание
1	Анализ литературы и предметной области	12	02.09.2024–30.11.2024	
2	Постановка задачи и формирование требований к архитектуре	10	01.12.2024–31.01.2025	
3	Проектирование и внедрение этапа с использованием NFS	18	01.02.2025–31.05.2025	
4	Анализ ограничений NFS и разработка целевой P2P/FUSE-архитектуры	18	01.06.2025–30.09.2025	
5	Разработка storage-agent, Redis-реестра и механизмов репликации чанков	16	01.10.2025–31.12.2025	
6	Разработка storage-mounter и интеграция с ML-runtime	14	01.01.2026–29.02.2026	
7	Нагрузочное тестирование, анализ результатов и оформление ВКР	12	01.03.2026–24.05.2026	

5. Исходные материалы и пособия

1. DeepSeek-AI. DeepSeek-V4-Pro. 2026. <https://huggingface.co/deepseek-ai/DeepSeek-V4-Pro>

2. Kubernetes Authors. Configure a Pod to Use a PersistentVolume for Storage. 2024. <https://kubernetes.io/docs/tasks/configure-pod-container/configure-persistent-volume-storage/>

3. Redis Labs. Redis Cluster Specification. 2024. <https://redis.io/docs/reference/cluster-spec/>

4. Szeredi M. FUSE: Filesystem in Userspace // Linux Symposium. 2010. С. 267—278

5. Kubernetes Authors. DaemonSet in Kubernetes. 2024. <https://kubernetes.io/docs/concepts/workloads/controllers/daemonset/>

6. Дата выдачи задания 02.09.2024

Руководитель _____

Задание принял к исполнению _____